

FACULTAD DE CIENCIAS SOCIALES
Y JURÍDICAS DE ELCHE



ESTADÍSTICA EMPRESARIAL
TRABAJO DE FIN DE GRADO
CURSO 2025-2026

Predicción de la tasa de abandono de clientes

ALUMNO: YUWEI GUAN
TUTOR: JOSÉ LUIS SAINZ-PARDO AUÑÓN

Contenido

1	RESUMEN.....	4
2	INTRODUCCIÓN	5
2.1	Contextualización y Justificación.....	5
2.2	Objetivos del Trabajo	6
2.3	Metodología.....	6
3	TÉCNICAS DE APRENDIZAJE AUTOMÁTICO	8
3.1	Introducción al Aprendizaje Supervisado.....	8
3.2	Regresión Logística	8
3.2.1	Fundamento Matemático	8
3.2.2	Interpretabilidad: Los Odds Ratios	9
3.3	Árboles de Decisión (CART).....	10
3.3.1	Criterio de División	10
3.3.2	Ventajas y Limitaciones	10
3.4	Random Forest (Bosques Aleatorios).....	10
3.4.1	Bagging y Aleatoriedad	11
3.4.2	Predicción por Votación	11
3.5	K-Vecinos Más Cercanos (k-NN)	11
3.5.1	Principio de Proximidad	12
3.5.2	Consideraciones del Modelo.....	13
3.6	Máquinas de Vectores de Soporte (SVM).....	13
3.6.1	El Hiperplano de Máximo Margen	13
3.6.2	El "Kernel Trick" y la No Linealidad	13
3.6.3	Ventajas y Desafíos.....	14
3.7	Métricas de Evaluación del Rendimiento.....	15
3.7.1	La Matriz de Confusión	15
3.7.2	La Paradoja de la Exactitud (Accuracy).....	16
3.7.3	Sensibilidad (Recall).....	16
3.7.4	Curva ROC y Área Bajo la Curva (AUC)	17
4	PROBLEMÁTICA DE LA PÉRDIDA DE CLIENTES EN EL SECTOR DE TELECOMUNICACIONES	19
4.1	Un Mercado Saturado y "Commoditizado"	19

4.2	La Economía de la Retención vs. Adquisición	19
4.3	El Fenómeno de la "Switching Economy"	20
5	ANÁLISIS DE DATOS	22
5.1	Fuente y Origen de los Datos	22
5.2	Diccionario de Variables	22
5.2.1	Variables Demográficas	22
5.2.2	Servicios Contratados.....	23
5.2.3	Información de la Cuenta y Facturación	23
5.3	La Variable Objetivo (Target)	24
5.4	Resumen Estadístico Preliminar	24
5.4.1	Integridad Estructural y Valores Nulos.....	24
5.4.2	Estadísticos de Variables Numéricas	24
5.4.3	Estadísticos de Variables Categóricas.....	26
5.5	Limpieza y Transformación de Datos (Preprocesamiento).....	28
5.5.1	Análisis y Tratamiento de Valores Nulos.....	28
5.5.2	Transformación de Tipos de Datos y Filtrado.....	29
5.5.3	Estructura Final del Conjunto de Datos	30
5.6	Análisis Exploratorio Bivariado (EDA): Factores de Riesgo y Correlación	30
5.6.1	Análisis del perfil de riesgo según variables categóricas	30
5.6.2	Impacto de las variables cuantitativas en el abandono.....	35
5.6.3	Análisis de correlación y multicolinealidad.....	36
5.7	Preprocesamiento final y Modelado Predictivo	38
5.7.1	Codificación de variables (One-Hot Encoding)	38
5.7.2	Metodología de validación: K-Fold Cross-Validation	39
5.7.3	Estandarización y Escalado de Variables.....	39
5.7.4	Entrenamiento del Modelo Base (SVM).....	40
5.7.5	Evaluación Global de la Línea Base (Modelos por Defecto)	41
5.7.6	Tratamiento del Desbalanceo de Clases: Estrategia de Pesos Penalizados	45
5.7.7	Resultados Comparativos de Clasificación tras el Balanceo	45
5.7.8	Diagnóstico de Sobreajuste en Modelos de Partición	48
5.7.9	Tratamiento empírico mediante Regularización (Poda)	49

5.7.10	Comportamiento paramétrico del SVM	51
5.7.11	Optimización Automatizada (GridSearchCV)	55
5.7.12	Interpretación de los Coeficientes del Modelo mediante Odds Ratios (OR)	59
5.7.13	Análisis del diagrama del Árbol de Decisión	62
5.7.14	Identificación de Factores Críticos: Importancia de Variables (Random Forest)	64
5.7.15	Optimización de k-NN mediante Selección de Características	66
5.7.16	Análisis Global de Modelos: Curva ROC y AUC	68
5.8	Simulación de Impacto Económico y Optimización de Ofertas	70
5.8.1	Metodología de la Simulación	70
5.8.2	Resultados y Punto de Inflexión	71
5.8.3	Conclusión del Análisis Económico	72
6	CONCLUSIONES	74
6.1	Síntesis del Proceso y Métodos Empleados	74
6.2	Evaluación del Cumplimiento de los Objetivos	75
6.3	Conclusiones Finales y Líneas de Actuación Comercial	77
7	BIBLIOGRAFÍA	79

1 RESUMEN

Este Trabajo de Fin de Grado diseña y evalúa una estrategia analítica para optimizar las campañas de retención de clientes (*churn*) en el sector de las telecomunicaciones mediante *Machine Learning*. El objetivo principal es sustituir el marketing masivo tradicional por un enfoque dirigido que anticipe el abandono de forma económicamente eficiente.

Para ello, se entrenaron, optimizaron y compararon cinco algoritmos de clasificación binaria: Regresión Logística, Árbol de Decisión, *Random Forest*, Máquinas de Vectores de Soporte (SVM) y *k*-Vecinos Más Cercanos (*k*-NN). Tras aplicar las técnicas correspondientes de ajuste por desbalanceo de clases y optimizar los hiperparámetros mediante validación cruzada, se fijó el *Recall* como la métrica estadística prioritaria para maximizar la detección de bajas. Posteriormente, se realizó una simulación financiera basada en curvas de elasticidad, la cual permite traducir las métricas estadísticas en impacto económico neto para el negocio.

Las conclusiones del estudio demuestran que maximizar el *Recall* mediante reglas rígidas —como ocurre con el Árbol de Decisión— resulta inviable para la empresa, ya que satura la campaña con falsos positivos que destruyen el margen de beneficio. En su lugar, el *Random Forest* y la Regresión Logística se consolidan como las opciones más rentables. Al emitir probabilidades continuas, estos modelos permiten ejecutar una optimización conjunta que sitúa el umbral de corte óptimo en el 55% de riesgo para aplicar un descuento eficiente del 19% al 20%, concentrando los recursos exclusivamente en aquellos segmentos donde se genera un retorno financiero neto positivo.

2 INTRODUCCIÓN

2.1 Contextualización y Justificación

En la actual era de la información, los datos se han convertido en uno de los activos más valiosos para la toma de decisiones estratégicas en el ámbito empresarial. La capacidad de recopilar, procesar y analizar grandes volúmenes de información ha transformado la manera en que las organizaciones interactúan con sus consumidores. Este cambio de paradigma es especialmente crítico en el sector de las telecomunicaciones, un mercado caracterizado por una alta saturación, una competencia agresiva y una oferta de servicios cada vez más homogénea.

En este contexto, las compañías operan en un entorno donde la diferenciación por producto es compleja y costosa. Por consiguiente, la ventaja competitiva reside en la capacidad de gestionar eficazmente la relación con el cliente. Uno de los mayores desafíos a los que se enfrenta el sector es la tasa de abandono o cancelación, conocida técnicamente como *Churn Rate*. Este fenómeno no solo implica una pérdida directa de ingresos recurrentes, sino que también afecta a la rentabilidad a largo plazo de la compañía.

Desde una perspectiva de negocio, la literatura académica y empresarial coincide en un principio fundamental: el coste de adquirir un nuevo cliente es significativamente superior —se estima que entre cinco y siete veces más— que el coste de retener a uno existente [1]. Ante esta realidad económica, la predicción anticipada del abandono se vuelve una prioridad estratégica. Si una empresa es capaz de identificar qué clientes tienen una alta probabilidad de darse de baja antes de que tomen la decisión, puede implementar acciones de fidelización dirigidas y personalizadas para evitar su marcha.

2.2 Objetivos del Trabajo

El objetivo principal de este Trabajo de Fin de Grado es desarrollar un modelo estadístico predictivo capaz de identificar a los clientes con mayor propensión al abandono en una empresa de servicios de telecomunicaciones. Para ello, se utilizará la base de datos pública "*Telco Customer Churn*", que contiene información demográfica, de servicios contratados y datos de facturación de más de 7.000 clientes.

De este objetivo general se desprenden los siguientes objetivos específicos:

1. **Analizar el perfil del cliente:** Realizar un Análisis Exploratorio de Datos (EDA) exhaustivo para detectar patrones de comportamiento y caracterizar los segmentos de clientes con mayor riesgo de fuga.
2. **Identificar variables clave:** Determinar, mediante técnicas estadísticas, qué factores (precio, tipo de contrato, antigüedad, etc.) influyen de manera significativa en la decisión de abandonar la compañía.
3. **Comparar técnicas de modelado:** Evaluar y comparar el rendimiento de diferentes algoritmos de aprendizaje supervisado, comenzando por modelos estadísticos clásicos como la **Regresión Logística**, debido a su alta interpretabilidad, y explorando técnicas de aprendizaje automático como los **Árboles de Decisión**.
4. **Evaluar el impacto en el negocio:** Interpretar los resultados no solo desde la métrica de error estadístico, sino desde su implicación económica, proponiendo estrategias de retención basadas en los hallazgos del modelo.

2.3 Metodología

Para alcanzar los objetivos propuestos, este trabajo sigue una metodología estructurada de Ciencia de Datos. El proceso abarca desde la limpieza y preprocesamiento de los datos —tratamiento de valores nulos, codificación de variables categóricas y detección de valores atípicos— hasta la fase de modelado y evaluación.

Todo el análisis estadístico y computacional se ha llevado a cabo utilizando el lenguaje de programación **Python**, empleando librerías de referencia en el

sector como **Pandas** y **NumPy** para la manipulación y análisis de datos, **Matplotlib** y **Seaborn** para la visualización gráfica, y **Scikit-learn** para la implementación de los algoritmos de aprendizaje automático. Esta elección se justifica por la versatilidad de Python, su predominancia actual en el entorno empresarial y su capacidad para integrar modelos de Machine Learning en entornos de producción.

3 TÉCNICAS DE APRENDIZAJE AUTOMÁTICO

3.1 Introducción al Aprendizaje Supervisado

El Aprendizaje Automático (Machine Learning) [2] es una rama de la Inteligencia Artificial que se centra en el desarrollo de algoritmos capaces de identificar patrones complejos en los datos para realizar predicciones o tomar decisiones sin ser programados explícitamente para cada regla. Dentro de este campo, el presente trabajo se enmarca en el **Aprendizaje Supervisado**.

En los problemas de aprendizaje supervisado, disponemos de un conjunto de datos etiquetado, denotado como $D = \{(x_i, y_i)\}_{i=1}^N$, donde x_i representa el vector de características (variables predictoras como precio, antigüedad, etc.) e y_i es la variable objetivo o respuesta. El objetivo es entrenar un modelo f tal que $f(x) \approx y$

Dado que en nuestro caso la variable objetivo de este estudio, el abandono de clientes (*Churn*), es una variable categórica dicotómica (toma dos valores: "Sí" o "No"), nos enfrentamos a un problema de **Clasificación Binaria**. A continuación, se detallan los fundamentos teóricos de los algoritmos seleccionados para este estudio.

3.2 Regresión Logística

La Regresión Logística [3] es el modelo de referencia (*benchmark*) en la estadística empresarial para problemas de clasificación binaria. A diferencia de la regresión lineal, que predice valores continuos, la regresión logística estima la probabilidad de que una observación pertenezca a la clase positiva ($Y = 1$, en este caso, el abandono).

3.2.1 Fundamento Matemático

El modelo utiliza la **función sigmoide** (o logística) para transformar una combinación lineal de las variables predictoras en un valor acotado entre 0 y 1. La diferencia visual entre intentar ajustar una línea recta y ajustar una curva sigmoide se aprecia en la **Figura 3.1**.

La probabilidad condicional de que un cliente abandone se expresa como:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

Donde:

- $P(Y = 1|X)$ es la probabilidad de abandono dado el vector de características X
- β_0 es la ordenada en el origen (intercepto).
- $\beta_1, \dots, \beta_p$ son los coeficientes estimados para cada variable predictora.




Figura 3.1. Comparación del ajuste de Regresión Lineal y Regresión Logística en datos binarios.

Fuente: Elaboración propia.

3.2.2 Interpretabilidad: Los Odds Ratios

La principal ventaja de este algoritmo en un entorno de negocio no es solo su capacidad predictiva, sino su explicabilidad. Mediante la transformación logit, podemos obtener los **Odds Ratios (OR)**, que se calculan como e^{β_i} . Un $OR > 1$ indica que un aumento en la variable predictora incrementa la probabilidad de abandono, mientras que un $OR < 1$ indica un efecto protector (disminuye la probabilidad). Esta característica permite cuantificar, por ejemplo, cuánto aumenta el riesgo de fuga por cada euro adicional en la factura mensual.

3.3 Árboles de Decisión (CART)

Los Árboles de Decisión [4] son algoritmos no paramétricos que modelan la relación entre las variables predictoras y la variable objetivo mediante reglas de decisión secuenciales. El resultado es una estructura jerárquica similar a un diagrama de flujo, fácil de visualizar e interpretar por gestores de negocio.

3.3.1 Criterio de División

El algoritmo funciona dividiendo recursivamente el espacio de datos en subconjuntos más homogéneos respecto a la variable objetivo. En la librería scikit-learn de Python, el algoritmo CART (*Classification and Regression Trees*) utiliza por defecto el índice de **Impureza de Gini** para evaluar la calidad de una división.

Para un nodo t con C clases, el índice Gini se define como:

$$Gini(t) = 1 - \sum_{i=1}^C (p_i)^2$$

Donde p_i es la proporción de observaciones de la clase i en el nodo t . El algoritmo busca la división que maximice la reducción de esta impureza.

3.3.2 Ventajas y Limitaciones

La principal ventaja de los árboles es que no requieren suposiciones sobre la distribución de los datos (como la normalidad) y capturan relaciones no lineales automáticamente. Sin embargo, su mayor debilidad es la tendencia al **sobreajuste (overfitting)**: el árbol puede crecer demasiado y memorizar el ruido de los datos de entrenamiento, perdiendo capacidad de generalización. Para mitigar esto, se emplean técnicas de poda (*pruning*) o limitaciones en la profundidad máxima del árbol (*max_depth*).

3.4 Random Forest (Bosques Aleatorios)

Si bien los árboles de decisión son modelos intuitivos, sufren de una alta varianza: un pequeño cambio en los datos de entrenamiento puede generar una estructura de árbol completamente diferente. Para solucionar esta limitación, surge el

algoritmo **Random Forest** [5], una técnica de aprendizaje por conjuntos (*Ensemble Learning*).

3.4.1 Bagging y Aleatoriedad

El fundamento de Random Forest se basa en el concepto de **Bagging** (*Bootstrap Aggregating*). El algoritmo entrena múltiples árboles de decisión de manera independiente, pero introduce dos niveles de aleatoriedad para asegurar que los árboles sean distintos entre sí (descorrelacionados):

1. **Muestreo Bootstrap:** Cada árbol se entrena con una muestra diferente de los datos originales, obtenida mediante muestreo con reemplazo.
2. **Selección de características:** En cada división (nodo) del árbol, el algoritmo no considera todas las variables predictoras disponibles, sino un subconjunto aleatorio de ellas.

3.4.2 Predicción por Votación

Para realizar una predicción sobre un cliente nuevo, el Random Forest pasa los datos por cada uno de los árboles que lo componen. En problemas de clasificación, el resultado final se decide por **votación mayoritaria**: el modelo asigna la clase (Abandono o No Abandono) que haya sido predicha por la mayoría de los árboles individuales.

Esta estrategia de "sabiduría de la multitud" reduce drásticamente el riesgo de sobreajuste (*overfitting*) y suele proporcionar una precisión superior a la de los modelos individuales, convirtiéndolo en uno de los algoritmos más potentes para datos tabulares.

3.5 K-Vecinos Más Cercanos (k-NN)

El algoritmo de los **k-Vecinos Más Cercanos** (k-NN) [6] es un método de aprendizaje basado en instancias, conocido como "aprendizaje perezoso" (*lazy learning*), ya que no construye un modelo interno explícito durante la fase de entrenamiento, sino que memoriza las instancias observadas.

3.5.1 Principio de Proximidad

La hipótesis subyacente es que observaciones con características similares tienden a tener la misma etiqueta de clase. Para clasificar a un nuevo cliente, el algoritmo:

1. Calcula la distancia matemática entre el nuevo cliente y todos los clientes de la base de datos histórica. La métrica más común es la **Distancia Euclidiana**:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

2. Selecciona los k registros más cercanos (vecinos).
3. Asigna la clase mayoritaria entre esos k vecinos.

El proceso se ilustra visualmente en la **Figura 3.2**, donde se busca clasificar un nuevo cliente basándose en sus $k = 3$ vecinos más próximos.




Figura 3.2. Esquema del funcionamiento del algoritmo k -NN para $k = 3$ vecinos. En este ejemplo, el nuevo cliente sería clasificado como "Abandono" por votación mayoritaria (2 contra 1).

Fuente: Elaboración propia.

3.5.2 Consideraciones del Modelo

Aunque es un algoritmo sencillo e intuitivo, presenta dos desafíos importantes para este estudio. Primero, su coste computacional es elevado en grandes volúmenes de datos, ya que debe calcular distancias contra toda la base de datos para cada predicción. Segundo, es muy sensible a la escala de las variables; por tanto, requiere que datos como "Cargos Mensuales" (rango 0-100) y "Antigüedad" (rango 0-72) sean normalizados o estandarizados previamente para que una variable no domine sobre la otra en el cálculo de la distancia.

3.6 Máquinas de Vectores de Soporte (SVM)

Las Máquinas de Vectores de Soporte (SVM) [7], desarrolladas originalmente por Vapnik, son un conjunto de algoritmos de aprendizaje supervisado potentes y versátiles, utilizados tanto para clasificación como para regresión. A diferencia de otros clasificadores que buscan simplemente una frontera de decisión que separe las clases, el algoritmo SVM busca la frontera **óptima**.

3.6.1 El Hiperplano de Máximo Margen

La intuición geométrica detrás de SVM consiste en encontrar un hiperplano (una línea en 2D, un plano en 3D, etc.) que separe las observaciones de la clase "Abandono" de las de "No Abandono". Sin embargo, existen infinitos hiperplanos posibles.

El algoritmo selecciona aquel que maximiza el margen, definido como la distancia entre el hiperplano y los puntos de datos más cercanos de cada clase (**ver Figura 3.3, Panel A**). A estos puntos críticos se les denomina Vectores de Soporte.

- Si el margen es amplio, el modelo generalizará mejor ante nuevos datos.
- Si el margen es estrecho, el modelo es más propenso al sobreajuste.

3.6.2 El "Kernel Trick" y la No Linealidad

En la realidad empresarial, rara vez los datos de clientes son linealmente separables (no se pueden separar con una simple línea recta). Para resolver

esto, SVM utiliza una técnica matemática conocida como **Kernel Trick** (Truco del Núcleo).

Esta técnica proyecta los datos originales a un espacio de dimensiones superiores (donde $X \rightarrow \phi(X)$) de tal manera que, en ese nuevo espacio de alta dimensión, las clases sí sean linealmente separables. Como se observa en la **Figura 3.3 (Panel B)**, el uso de kernels permite definir fronteras de decisión curvas y complejas. En este trabajo, al utilizar la implementación de *scikit-learn* en Python, se empleará habitualmente el kernel RBF (Radial Basis Function).




Figura 3.3. Comparación de fronteras de decisión: SVM Lineal (Panel A) y Kernel RBF (Panel B).

Fuente: Elaboración propia.

3.6.3 Ventajas y Desafíos

La principal fortaleza de SVM reside en su eficacia en espacios de grandes dimensiones y su robustez ante el sobreajuste, especialmente cuando el número de dimensiones (variables) es mayor que el número de muestras. No obstante, presenta una limitación importante frente a los Árboles de Decisión: es un modelo de "caja negra", especialmente si se usa el Kernel Trick. La interpretación de los resultados no es directa; no obtenemos reglas sencillas tipo "Si $X > 5$...", lo que ~ dificulta la explicación comercial de por qué un cliente específico ha sido clasificado como riesgo de fuga.

3.7 Métricas de Evaluación del Rendimiento

La fase de evaluación es crítica en cualquier proyecto de ciencia de datos, pues determina la viabilidad operativa del modelo. En problemas de clasificación con clases desbalanceadas, como la predicción de fugas (*churn*), el uso de métricas convencionales puede llevar a conclusiones erróneas sobre la calidad del modelo [8].

3.7.1 La Matriz de Confusión

La herramienta fundamental para evaluar el desempeño de un clasificador es la Matriz de Confusión. Se trata de una tabla de doble entrada que contrasta las predicciones del modelo con la realidad observada, tal y como se esquematiza en la **Figura 3.4**. De ella se extraen cuatro conteos básicos:

- **Verdaderos Positivos (TP):** Clientes que realmente abandonaron y el modelo los detectó correctamente. (Éxito del modelo).
- **Verdaderos Negativos (TN):** Clientes fieles que el modelo clasificó correctamente como fieles.
- **Falsos Positivos (FP):** Clientes fieles que el modelo etiquetó erróneamente como riesgo de fuga (Error de Tipo I).
- **Falsos Negativos (FN):** Clientes que abandonaron la compañía, pero el modelo predijo que se quedarían (Error de Tipo II).

En el contexto de negocio de este TFG, el **Falso Negativo (FN)** es el error más costoso, ya que implica perder un cliente sin haber tenido la oportunidad de retenerlo.

Esquema conceptual de la Matriz de Confusión

Etiqueta Real (Valor Verdadero) Realidad: No Fuga	Verdadero Negativo (TN) Cliente que permanece clasificado correctamente	Falso Positivo (FP) Error Tipo I: Alarma de fuga falsa
	Falso Negativo (FN) Error Tipo II: Fuga no detectada	Verdadero Positivo (TP) Cliente en fuga clasificado correctamente
	Predicción: No Fuga	Predicción: Fuga
	Etiqueta Predicha (Salida del Modelo)	

Figura 3.4. Estructura de la Matriz de Confusión en problemas de detección de abandono.

Fuente: Elaboración propia.

3.7.2 La Paradoja de la Exactitud (Accuracy)

La métrica más intuitiva es la Exactitud, definida como el porcentaje total de aciertos:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Sin embargo, en bases de datos desbalanceadas (ej. 80% fieles, 20% fugas), un modelo "ingenuo" que prediga sistemáticamente que **nadie** se va, obtendría una exactitud del 80%. A pesar de su alta "nota", dicho modelo sería inútil para la empresa, pues no detectaría ninguna fuga. Por esta razón, se priorizarán métricas sensibles a la clase minoritaria.

3.7.3 Sensibilidad (Recall)

Dada la prioridad estratégica de detectar a los clientes fugados, la métrica principal de este estudio será la Sensibilidad (también llamada *Recall* o Tasa de

Verdaderos Positivos). Mide la capacidad del modelo para encontrar todos los casos positivos:

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

Un modelo con alta sensibilidad minimiza los Falsos Negativos, asegurando que la mayoría de los clientes en riesgo sean detectados.

3.7.4 Curva ROC y Área Bajo la Curva (AUC)

Finalmente, para evaluar la calidad global del modelo sin depender de un único umbral de decisión, se empleará la curva ROC (*Receiver Operating Characteristic*). Esta herramienta gráfica (**ver Figura 3.5**) permite visualizar el equilibrio entre dos aspectos contrapuestos: la capacidad de detectar correctamente a los clientes que se van (Sensibilidad) frente al error de dar falsas alarmas con clientes que se quedan (Tasa de Falsos Positivos).

Para cuantificar este rendimiento en un único indicador, se calcula el **AUC (Área Bajo la Curva)**. En términos prácticos, el AUC evalúa el grado de separación entre las dos categorías de clientes. Dicho de otro modo, mide la habilidad del modelo para construir un "ranking" de riesgo preciso: en un modelo ideal, los clientes que realmente abandonaron la empresa ocuparán siempre las posiciones más altas de riesgo, quedando claramente separados de los clientes fieles [9]. Cuanto mayor sea la capacidad del algoritmo para distinguir y separar a ambos grupos, mayor será el valor del área.

La escala de valoración estándar es:

- **AUC = 0.5:** El modelo no tiene capacidad discriminante (los clientes fieles y los fugados se mezclan en el ranking de riesgo sin orden alguno). Su rendimiento equivale a lanzar una moneda al aire.
- **$0.7 \leq \text{AUC} < 0.8$:** Se considera un rendimiento aceptable para aplicaciones de negocio.
- **$\text{AUC} \geq 0.8$:** El modelo presenta una capacidad discriminante excelente, logrando separar con claridad ambas clases de clientes.




Figura 3.5. Comparación de rendimiento ROC: Modelo predictivo vs. Azar.

Fuente: Elaboración propia.

4 PROBLEMÁTICA DE LA PÉRDIDA DE CLIENTES EN EL SECTOR DE TELECOMUNICACIONES

4.1 Un Mercado Saturado y "Commoditizado"

El sector de las telecomunicaciones ha experimentado una transformación radical en las últimas dos décadas. Hemos pasado de un escenario de crecimiento expansivo, donde el objetivo era captar nuevos usuarios que accedían por primera vez a la telefonía o internet, a una etapa de **madurez y saturación**.

En la actualidad, la penetración de servicios móviles en países desarrollados supera a menudo el 100% de la población. Esto implica que el mercado es un "juego de suma cero": para que una compañía gane un cliente, necesariamente debe arrebatarárselo a un competidor.

A esta saturación se suma el fenómeno de la **"commoditización"** de los servicios. Para el consumidor medio, la diferencia técnica entre la fibra óptica de un operador u otro es imperceptible. Cuando el producto es percibido como idéntico, la competencia se traslada casi exclusivamente al precio, generando una guerra de precios que erosiona los beneficios netos. Este escenario, sumado a la facilidad regulatoria para cambiar de proveedor, elimina los incentivos de permanencia, dejando a las operadoras en una situación de alta vulnerabilidad ante el *churn* o fuga de clientes.

4.2 La Economía de la Retención vs. Adquisición

Desde una perspectiva financiera, la gestión de la tasa de cancelación (*Churn Rate*) no es un problema técnico, sino de rentabilidad. La literatura económica empresarial es contundente respecto a la disparidad de costes entre captar y retener.

Según la investigación clásica de **Frederick Reichheld**, creador del sistema NPS (Net Promoter Score) y socio de **Bain & Company**, aumentar las tasas de retención de clientes en tan solo un 5% puede incrementar los beneficios de la

empresa entre un **25% y un 95%** [10]. Este impacto desproporcionado se debe a que los clientes fieles no solo generan ingresos recurrentes sin coste de adquisición asociado, sino que tienden a contratar servicios adicionales (*up-selling* y *cross-selling*) y actúan como prescriptores de la marca.

Por el contrario, el coste de adquirir un nuevo cliente (CAC - *Customer Acquisition Cost*) incluye publicidad, comisiones de venta, instalación de equipos y promociones de entrada. **Amy Gallo**, en su análisis para la **Harvard Business Review**, destaca que adquirir un nuevo cliente es, dependiendo del sector, entre **5 y 25 veces más costoso** que retener a uno existente [11].

En el sector "Telco", donde los costes fijos de infraestructura son enormes, perder a un cliente antes de recuperar su coste de adquisición (que suele tardar entre 6 y 12 meses en amortizarse) supone una destrucción directa de valor para la compañía.

4.3 El Fenómeno de la "Switching Economy"

El comportamiento del consumidor también ha evolucionado. Nos encontramos ante clientes más informados, menos fieles y más exigentes. Un informe global de **Accenture** acuñó el término "*Switching Economy*" (Economía del Cambio) para describir los billones de dólares que cambian de manos anualmente debido a clientes que abandonan sus proveedores por una mala experiencia o mejores ofertas [12].

En telecomunicaciones, las principales causas económicas del abandono suelen agruparse en tres categorías:

1. **Precio y Facturación:** Percepción de precios elevados o cargos inesperados (como se verá en las variables *MonthlyCharges* de nuestro dataset).
2. **Calidad del Servicio:** Fallos técnicos o mala atención al cliente.
3. **Inercia Competitiva:** Ofertas agresivas de la competencia dirigidas específicamente a la base de clientes de otros operadores.

Ante este escenario, las empresas ya no pueden permitirse una estrategia reactiva (intentar retener al cliente cuando ya ha llamado para darse de baja). La única vía para proteger la cuenta de resultados es la **predicción proactiva**: utilizar los datos históricos para identificar el riesgo de fuga antes de que el cliente tome la decisión de irse.

5 ANÁLISIS DE DATOS

5.1 Fuente y Origen de los Datos

Para la parte experimental de este Trabajo de Fin de Grado se ha utilizado el conjunto de datos público "**Telco Customer Churn**", disponible originalmente en la plataforma IBM Business Analytics y distribuido ampliamente a través del repositorio de ciencia de datos **Kaggle**.

Este dataset contiene información histórica de una empresa de telecomunicaciones ficticia que opera en California (EE. UU.) en el tercer trimestre (Q3). Aunque los datos son sintéticos para preservar la privacidad, han sido diseñados por IBM para reflejar fielmente los patrones de comportamiento reales en la industria de las telecomunicaciones.

El archivo original (WA_Fn-UseC_-Telco-Customer-Churn.csv) consta de **7.043 registros** (filas), donde cada registro representa a un cliente único, y **21 variables** (columnas) que describen sus características demográficas, los servicios contratados y su estado de facturación.

5.2 Diccionario de Variables

Las variables del estudio se pueden clasificar en tres grandes bloques funcionales: información demográfica, servicios suscritos e información de la cuenta. A continuación, se detalla el significado de cada una:

5.2.1 Variables Demográficas

Estas variables permiten perfilar al cliente más allá de su relación comercial:

- **gender**: Género del cliente (Male/Female).
- **SeniorCitizen**: Indicador binario (1/0) que señala si el cliente es una persona mayor (jubilado).
- **Partner**: Indica si el cliente tiene pareja (Yes/No).
- **Dependents**: Indica si el cliente tiene personas a su cargo, como hijos o familiares dependientes (Yes/No).

5.2.2 Servicios Contratados

Describen los productos que el cliente tiene activos con la compañía:

- **PhoneService:** Indica si tiene servicio telefónico contratado (Yes, No).
- **MultipleLines:** Indica si dispone de múltiples líneas telefónicas (Yes, No, No phone service).
- **InternetService:** Tipo de conexión a internet (DSL, Fiber optic, No).
- **OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies:** Conjunto de servicios adicionales (seguridad, soporte, streaming, etc.) que el cliente puede tener contratados (Yes, No, No internet service).

5.2.3 Información de la Cuenta y Facturación

Variables financieras críticas que suelen presentar una alta correlación con la decisión de abandono:

- **Tenure:** Antigüedad del cliente en la empresa, medida en meses completos.
- **Contract:** Tipo de contrato (Month-to-month, One year, Two year). Esta variable es fundamental para entender la flexibilidad de salida del cliente.
- **PaperlessBilling:** Si el cliente utiliza facturación electrónica sin papel (Yes/No).
- **PaymentMethod:** Método de pago (Electronic check, Mailed check, Bank transfer, Credit card).
- **MonthlyCharges:** Importe mensual facturado al cliente (en dólares).
- **TotalCharges:** Importe total acumulado facturado al cliente desde el inicio de su relación contractual.

5.3 La Variable Objetivo (Target)

La variable dependiente que los modelos de aprendizaje supervisado intentarán predecir es:

- **Churn:** Variable categórica binaria.
 - **"Yes":** Indica que el cliente canceló el servicio durante el último mes (abandono).
 - **"No":** Indica que el cliente permanece activo en la compañía (fiel).

5.4 Resumen Estadístico Preliminar

Antes de aplicar cualquier técnica de preprocesamiento o limpieza, se realizó una exploración estadística descriptiva sobre los datos brutos (*raw data*) para comprender las distribuciones y detectar posibles anomalías en los tipos de datos.

5.4.1 Integridad Estructural y Valores Nulos

Acorde con la descripción inicial de los datos (apartado 5.1), el análisis de la estructura del *dataframe* confirma que el conjunto contiene **7.043 observaciones** y **21 variables**. La gran mayoría de las columnas presentan una integridad del 100%, es decir, carecen de valores perdidos explícitos.

Sin embargo, la exploración mediante herramientas estadísticas ha detectado que existen **11 valores perdidos (*Missing Values*) en la variable *TotalCharges***, los cuales representan una proporción mínima del **0.15%** respecto a la muestra total. La investigación sobre el origen de estos nulos y la decisión metodológica sobre su tratamiento (ya sea mediante imputación matemática o eliminación directa) se abordará en detalle durante la fase de preprocesamiento en el apartado 5.5.

5.4.2 Estadísticos de Variables Numéricas

El análisis descriptivo de las variables cuantitativas revela información clave sobre la fidelidad y la facturación de los usuarios. Los hallazgos más relevantes, apoyados en las medidas estadísticas de la **Tabla 5.1** y en las distribuciones visuales de la **Figura 5.2**, se resumen a continuación:

- **Antigüedad (*Tenure*):** La permanencia oscila entre 0 y 72 meses, con una media de 32,37 meses. Sin embargo, su histograma revela claramente una **distribución bimodal**. Esto revela que la antigüedad de los clientes está fuertemente polarizada. Por una parte, destaca un amplio volumen de usuarios recién contratados (lo que sugiere una alta entrada y salida de clientes) y, por otra, existe una base consolidada de usuarios muy fieles que alcanzan el periodo máximo de permanencia (cercano a los 6 años).
- **Cargos Mensuales (*MonthlyCharges*):** El gasto medio se sitúa en 64,76 dólares. Como refleja la tabla, existe una amplia brecha entre las tarifas básicas (18,25 dólares) y los paquetes *premium* (118,75 dólares). Visualmente, el gráfico destaca una alta densidad de clientes concentrados en el tramo más económico (alrededor de 20 dólares).
- **Cargos Totales (*TotalCharges*):** Derivado de la variabilidad en la antigüedad y en el tipo de tarifa, el importe total facturado presenta una enorme dispersión, con una desviación típica (2.266,80 dólares) que prácticamente iguala a su media. Su representación gráfica muestra una marcada **distribución asimétrica positiva** (sesgada hacia la derecha), típica en variables de facturación acumulada.
- **Tercera Edad (*SeniorCitizen*):** Aunque originalmente tratada como numérica por su codificación binaria (0 y 1), su media de 0,162 se interpreta de forma directa como una proporción: apenas el **16,2%** de la base de clientes está compuesta por personas de la tercera edad, confirmando visualmente su naturaleza categórica.

Variable	Media	Desv. Std	Mín	Mediana (50%)	Máx	Interpretación
SeniorCitizen	0.162	0.37	0.0	0.0	1.0	El 16.2% de los clientes son jubilados/personas mayores.
Tenure (meses)	32.37	24.56	0.0	29.0	72.0	Distribución bimodal (muchos clientes nuevos y muchos antiguos).
MonthlyCharges	64.76	30.09	18.25	70.35	118.75	El gasto medio mensual es de aprox. 65\$.
TotalCharges	2283.30	2266.80	18.80	1397.50	8684.80	Gran dispersión debido a la variabilidad en la antigüedad.

Tabla 5.1. Resumen estadístico de las variables numéricas.

Fuente: Elaboración propia a partir de la salida de Python.




Figura 5.2. Histograma para ver la distribución de las variables numéricas.

Fuente: Elaboración propia.

5.4.3 Estadísticos de Variables Categóricas

El estudio de las frecuencias absolutas en las variables cualitativas permite perfilar las características modales del cliente promedio y dimensionar la variable objetivo. En la **Tabla 5.3** se presenta el resumen estadístico de las variables categóricas, detallando el número de categorías únicas, la clase mayoritaria (moda) y su frecuencia absoluta.

Variable	Descripción	Recuento	Val. Únicos	Categoría más Frecuente (Moda)	Frec. Absoluta
customerID	Identificador del cliente	7.043	7.043	3186-AJIEK	1
gender	Género	7.043	2	Male (Hombre)	3.555
Partner	Convivencia en pareja	7.043	2	No	3.641
Dependents	Personas a cargo	7.043	2	No	4.933
PhoneService	Servicio telefónico	7.043	2	Yes (Sí)	6.361
MultipleLines	Líneas múltiples	7.043	3	No	3.390
InternetService	Tipo de internet	7.043	3	Fiber optic (Fibra óptica)	3.096
OnlineSecurity	Seguridad en línea	7.043	3	No	3.498
OnlineBackup	Copia de seguridad	7.043	3	No	3.088
DeviceProtection	Protección de dispositivo	7.043	3	No	3.095
TechSupport	Soporte técnico	7.043	3	No	3.473
StreamingTV	Servicio de TV	7.043	3	No	2.810
StreamingMovies	Servicio de películas	7.043	3	No	2.785
Contract	Tipo de contrato	7.043	3	Month-to-month (Mensual)	3.875
PaperlessBilling	Facturación electrónica	7.043	2	Yes (Sí)	4.171
PaymentMethod	Método de pago	7.043	4	Electronic check (Cheque elec.)	2.365
Churn	Fuga de clientes (Target)	7.043	2	No	5.174

Tabla 5.3. Resumen estadístico de las variables categóricas.

Fuente: Elaboración propia a partir de la salida de Python.

A partir de los resultados mostrados en la **Tabla 5.3**, se extraen las siguientes conclusiones fundamentales sobre la composición de la cartera de clientes:

- **Variable Objetivo (Churn):** Se constata un claro desbalanceo en la clase a predecir. La gran mayoría de los usuarios (5.174 clientes, que representan el 73,5% del total) permanecen fieles a la compañía ("No"). Por tanto, la tasa de abandono se sitúa en el 26,5%. Tal y como se muestra en la Figura 5.4.




Figura 5.4. Distribución de la tasa de abandono.

Fuente: Elaboración propia

- **Perfil Demográfico:** La distribución por género es prácticamente equitativa, con una ligerísima mayoría de hombres (3.555 frente a 3.488 mujeres). En cuanto a la estructura familiar, la moda indica que el cliente

típico no convive en pareja ("No": 3.641) ni tiene personas a su cargo ("No": 4.933).

- **Servicios Contratados:** La penetración del servicio telefónico es casi universal en la base de datos (6.361 clientes). En el apartado de conectividad, la infraestructura predominante es la Fibra Óptica (3.096 hogares). Llama la atención que, para todos los servicios de valor añadido (seguridad en línea, soporte técnico, copias de seguridad, etc.), la categoría mayoritaria es la no contratación de los mismos.
- **Contratación y Facturación:** El nivel de compromiso comercial es predominantemente a corto plazo. Más de la mitad de la cartera (3.875 clientes) dispone de un contrato de renovación mensual sin permanencia (*Month-to-month*). Además, el método de pago más utilizado es el cheque electrónico (2.365) y existe una clara preferencia por la facturación sin papel (4.171).
- **Identificador Único:** Como era de esperar, la variable `customerID` presenta 7.043 valores únicos, confirmando que no existen registros duplicados en la base de datos. Al carecer de varianza explicativa, esta variable será descartada en la fase de preprocesamiento.

5.5 Limpieza y Transformación de Datos (Preprocesamiento)

Una vez identificadas las características y anomalías del conjunto de datos bruto, se procedió a diseñar un flujo de limpieza (*pipeline*) para adecuar la información a los requisitos matemáticos de los algoritmos de Machine Learning.

5.5.1 Análisis y Tratamiento de Valores Nulos

Como se detectó en el análisis preliminar, la variable `TotalCharges` presentaba 11 valores nulos (espacios en blanco). Antes de tomar una decisión sobre su tratamiento, se realizó un filtrado específico para aislar y estudiar a estos clientes.

Al cruzar estos 11 registros con el resto de variables, se descubrió un patrón unánime: **todos ellos presentaban una antigüedad (tenure) igual a 0**. Esto indica que se trata de clientes recién adquiridos por la compañía a los que aún no se les ha emitido su primer ciclo de facturación mensual. Dado que no

disponen de historial financiero y representan una fracción marginal del dataset (0.15%), se procedió a la eliminación de estas 11 filas (*Drop NA*).

5.5.2 Transformación de Tipos de Datos y Filtrado

Tras gestionar los valores ausentes, se aplicaron las siguientes transformaciones estructurales:

1. **Recodificación de SeniorCitizen:** El análisis inicial detectó que esta variable estaba codificada como un número entero (0 y 1). Para evitar que los algoritmos de regresión la interpretaran erróneamente como una variable cuantitativa continua (donde 1 "vale más" que 0), se recodificó a formato cualitativo o factor ("No" / "Sí").
2. **Tipificación de Factores:** Todas las variables almacenadas como cadenas de texto genéricas (chr u object, como gender o Partner) fueron convertidas explícitamente a variables categóricas. Este paso es fundamental para el correcto funcionamiento de las librerías de modelado y la posterior creación de variables *dummy*.
3. **Eliminación de Identificadores:** Se suprimió la columna customerID. Al tratarse de un código alfanumérico único para cada usuario, carece de varianza explicativa y no aporta ninguna capacidad predictiva al modelo, actuando únicamente como "ruido" computacional.
4. **Reajuste del Índice:** Como consecuencia de la eliminación de los registros con valores nulos, el índice del conjunto de datos presentaba saltos en su numeración. Para evitar desalineaciones estructurales en las futuras iteraciones de la validación cruzada (*Cross-Validation*), se procedió a resetear y reconstruir el índice de forma secuencial, garantizando la continuidad de las filas.
5. **Binarización de la Variable Objetivo:** Para posibilitar futuros cálculos estadísticos (como las matrices de correlación) y optimizar el entrenamiento de los algoritmos de clasificación, se generó una versión numérica de la variable dependiente Churn. Se aplicó una codificación binaria estándar, asignando el valor 1 a los eventos positivos de abandono

("Yes") y 0 a los clientes retenidos ("No"), almacenando el resultado en la nueva variable Churn_Num.

5.5.3 Estructura Final del Conjunto de Datos

Tras ejecutar estas operaciones de limpieza, el conjunto de datos resultante (df_clean) quedó configurado por **7.032 observaciones y 21 variables** (19 características predictoras más las **dos representaciones, categórica y numérica, de la variable objetivo**). Este *dataset* depurado y estructurado constituye la base analítica definitiva sobre la que se desarrollará el Análisis Exploratorio Visual y el posterior entrenamiento de los modelos predictivos.

5.6 Análisis Exploratorio Bivariado (EDA): Factores de Riesgo y Correlación

Una vez depurado el conjunto de datos, este apartado aborda el Análisis Exploratorio de Datos (EDA) desde una perspectiva bivariada. El objetivo fundamental es identificar qué variables presentan una relación estadística o visualmente significativa con la fuga de clientes (*Churn*).

Para ello, se estructurará el análisis en tres fases: primero, se examinará el impacto de las variables cualitativas mediante gráficos de barras apiladas al 100%; segundo, se analizará la distribución de las variables numéricas clave a través de diagramas de caja (*Boxplots*); y finalmente, se realizará un estudio de correlación lineal para cuantificar las relaciones entre las variables cuantitativas y detectar posibles problemas de multicolinealidad que pudieran afectar a los futuros modelos de Machine Learning.

5.6.1 Análisis del perfil de riesgo según variables categóricas

Para identificar los factores que impulsan la fuga de clientes, se ha optado por un análisis de **proporciones apiladas al 100%**. Este enfoque permite visualizar directamente la **tasa de abandono** (probabilidad de fuga) dentro de cada categoría, independientemente del volumen total de clientes que la compongan.

A. El impacto del modelo de contratación, la infraestructura y la facturación

La relación estructural y económica con el cliente es el determinante más fuerte de la fuga. Como se observa en la Figura 5.5., el riesgo se concentra en segmentos muy específicos:




Figura 5.5. Análisis de abandono según modelo de contratación, la infraestructura y la facturación

Fuente: Elaboración propia

- **Fricción contractual:** El tipo de contrato es el factor predictor más evidente. La inmensa mayoría de los abandonos provienen de usuarios con contratos de renovación mensual (*Month-to-month*), quienes carecen de barreras de salida. Por el contrario, los clientes con compromisos a uno o dos años muestran una fidelidad casi absoluta.
- **La paradoja de la Fibra Óptica:** Resulta notable que los usuarios de Fibra Óptica, el servicio teóricamente superior y de mayor coste, presentan tasas de fuga significativamente más altas que los usuarios de ADSL (*DSL*). Esto sugiere posibles problemas de calidad en el servicio, expectativas no cumplidas o una presión competitiva agresiva en este segmento específico.
- **Dinámicas de Pago y Facturación:** Los clientes que utilizan el cheque electrónico (*Electronic check*) muestran una propensión al abandono mucho

mayor. Curiosamente, la **facturación electrónica** (*Paperless Billing*) también se asocia a una mayor tasa de fuga. Este fenómeno es habitual en el sector *tel/co*, ya que los clientes "digitalizados" suelen tener mayor facilidad y agilidad para comparar ofertas y tramitar portabilidades de forma puramente online.

B. Los servicios de valor añadido como barrera de salida

Más allá de la conectividad básica, el ecosistema de servicios complementarios juega un papel crucial en la fidelización. La Figura 5.6. muestra el comportamiento del *Churn* según la adopción de cuatro servicios de protección clave:




Figura 5.6. Análisis de abandono según Servicios de valor añadido

Fuente: Elaboración propia

Se evidencia un patrón unánime y contundente: los clientes que **no contratan** estos servicios de valor añadido (*Online Security, Tech Support, Online Backup y Device Protection*) presentan tasas de abandono drásticamente superiores. Por el contrario, aquellos que aseguran sus dispositivos y datos, o cuentan con soporte técnico experto, tienden a permanecer en la compañía. Estos servicios

actúan como eficaces "barreras de salida", aumentando el coste de cambio percibido por el cliente y mitigando la frustración ante posibles incidencias.

C. Variables sociodemográficas y servicios de conveniencia

Para completar el análisis bivariado, se examinan aquellas variables que, si bien no representan los ejes críticos de fuga identificados anteriormente, permiten perfilar de manera integral al consumidor. La Figura 5.7. recoge el impacto del perfil demográfico y de los servicios de entretenimiento y conectividad básica.

- **Perfil Demográfico y Familiar:** Se observa una notable paridad en la tasa de abandono según el género, lo que sugiere que las estrategias de retención no requieren una segmentación por sexo. Sin embargo, la variable **Senior Citizen** (Tercera Edad) revela que este colectivo presenta una tasa de fuga proporcionalmente superior a la media, situándose cerca del **42%**, lo que los convierte en un segmento de vulnerabilidad comercial. Por otro lado, los clientes con pareja (Partner) o personas a cargo (Dependents) muestran una mayor estabilidad, probablemente asociada a una mayor complejidad en la gestión de cambios de domicilio o servicios compartidos.
- **Servicios de Conectividad y Entretenimiento:** Variables como la tenencia de múltiples líneas telefónicas o el uso de servicios de Streaming (TV y Películas) presentan distribuciones de abandono muy equilibradas. Estos servicios parecen actuar más como factores de incremento del gasto mensual que como verdaderos disparadores de fidelidad o abandono. Asimismo, la presencia del servicio telefónico básico es casi universal en el dataset y no muestra una correlación significativa con la decisión de fuga.

En conclusión, este tercer bloque confirma que, aunque el perfil demográfico aporta matices (especialmente en el caso de los jubilados), el "corazón" del problema del Churn reside en la estructura del contrato y la percepción de seguridad y soporte técnico analizados previamente.




Figura 5.7. Análisis de abandono según variables demográficas, servicios telefónicos y de entretenimiento.

Fuente: Elaboración propia

5.6.2 Impacto de las variables cuantitativas en el abandono

Tras evaluar el perfil categórico, resulta fundamental analizar cómo las variables numéricas continuas o discretas afectan a la decisión de fuga. Para ello, se emplean diagramas de caja (*Boxplots*), los cuales permiten visualizar de manera robusta las diferencias en la mediana, la dispersión y la presencia de valores atípicos entre los clientes retenidos y los que han abandonado la compañía.

Como se ha justificado metodológicamente, este análisis se centra en las dos dimensiones temporales y económicas puras: la antigüedad del cliente (*Tenure*) y su cuota mensual (*Monthly Charges*). La variable de facturación total (*Total Charges*) se omite en este análisis visual bivariado debido a su alta dependencia matemática con la antigüedad, lo que podría generar interpretaciones espurias, reservándose para el análisis de correlación posterior.

La **Figura 5.8.** expone la distribución poblacional de ambas variables predictoras:




Figura 5.8. Boxplots para variables numéricas.

Fuente: Elaboración propia

- **El factor de la fidelización temprana (Antigüedad):** El primer diagrama revela una diferencia drástica en el tiempo de permanencia. La mediana de antigüedad de los clientes que abandonan la compañía (línea central de la caja azul) se sitúa en tan solo 10 meses. Además, se observa que la inmensa mayoría de las bajas se concentran en las primeras etapas de

vida del cliente. Concretamente, el tercer cuartil (el límite superior de la caja azul) se sitúa en torno a los 29 meses, lo que significa que el 75% de los clientes que abandonan la compañía lo hacen antes de cumplir los dos años y medio de contrato. Por el contrario, los clientes retenidos presentan una mediana que ronda los 38 meses, con una distribución mucho más amplia. Esto evidencia que el riesgo de fuga es extremadamente alto durante los primeros compases del ciclo de vida del cliente; superar esta barrera inicial parece consolidar la retención a largo plazo.

- **La sensibilidad al precio (Cargos Mensuales):** El segundo diagrama confirma que el factor económico juega un rol determinante. Los usuarios que se dan de baja soportan, por lo general, cuotas mensuales significativamente más altas. La mediana del gasto mensual para el grupo de abandono se sitúa próxima a los **80 dólares**, frente a los **64 dólares** de mediana del grupo retenido. Asimismo, se observa que el cuartil inferior de los clientes fugados comienza muy por encima del de los retenidos, indicando que las tarifas económicas (planes básicos) actúan como un fuerte anclaje de fidelidad, mientras que los planes más costosos generan una mayor propensión a la insatisfacción y rotación.

En síntesis, el análisis cuantitativo dibuja un perfil de alto riesgo muy claro: clientes en su **primer año de contrato** que están asumiendo **cuotas mensuales elevadas**.

5.6.3 Análisis de correlación y multicolinealidad

Para finalizar el Análisis Exploratorio de Datos, se ha calculado la matriz de correlación lineal de Pearson entre las variables cuantitativas del *dataset* y la variable objetivo transformada a formato numérico (*Churn_Num*). Este análisis permite cuantificar la fuerza y dirección de las relaciones lineales, así como detectar posibles problemas de multicolinealidad estructural que deban corregirse antes de la fase de modelado predictivo.

La **Figura 5.9.** muestra el mapa de calor (*Heatmap*) resultante:




Figura 5.8. Matriz de correlación.

Fuente: Elaboración propia

La interpretación de los coeficientes revela dos dimensiones de análisis crítico para el posterior desarrollo de los algoritmos de *Machine Learning*:

1. **Relación lineal con la variable objetivo (*Churn*)** Los coeficientes de correlación con *Churn_Num* confirman matemáticamente los hallazgos visuales de los diagramas de caja:
 - **Correlación negativa con la Antigüedad (-0.35):** Es la variable numérica con mayor poder predictivo lineal. Su signo negativo indica matemáticamente que a mayor número de meses de permanencia (*tenure*), la probabilidad de abandono disminuye, validando la importancia de la fidelización temprana.
 - **Correlación positiva con el Cargo Mensual (0.19):** Aunque moderada, la relación positiva confirma que incrementos en la cuota mensual (*MonthlyCharges*) se asocian linealmente con un aumento en la propensión a la fuga.
2. **Detección de Multicolinealidad** El hallazgo más relevante desde el punto de vista técnico es la fuerte relación detectada entre las variables

predictoras independientes. Se observa una **correlación positiva muy alta (0.83)** entre la antigüedad (*tenure*) y los cargos totales (*TotalCharges*). Esta relación es esperable por la propia naturaleza del negocio, ya que la facturación total es una variable derivada del producto entre la cuota mensual y el tiempo de permanencia. Adicionalmente, *TotalCharges* también presenta una correlación significativa (0.65) con *MonthlyCharges*.

Conclusión y decisión metodológica: La presencia de una correlación superior a 0.80 indica un claro problema de multicolinealidad. Introducir variables tan altamente correlacionadas en algoritmos sensibles a este fenómeno (como la Regresión Logística) puede generar sobreajuste (*overfitting*) e inestabilidad en los coeficientes del modelo. Por ello, la decisión metodológica de cara a la fase de preprocesamiento será **prescindir de la variable *TotalCharges***. De este modo, se retiene toda la información fundamental a través de sus componentes base (*tenure* y *MonthlyCharges*), manteniendo un *dataset* más limpio, independiente y robusto para el entrenamiento de los modelos predictivos.

5.7 Preprocesamiento final y Modelado Predictivo

Tras concluir la fase de Análisis Exploratorio de Datos (EDA), este apartado aborda la transformación definitiva del conjunto de datos y el entrenamiento de una primera aproximación mediante algoritmos de *Machine Learning* capaces de predecir la fuga de clientes.

5.7.1 Codificación de variables (One-Hot Encoding)

Para adecuar el conjunto de datos a los requisitos matemáticos de los algoritmos de clasificación, se llevó a cabo una codificación de variables ficticias (*Dummy variables* o *One-Hot Encoding*). Este proceso transforma todas las características categóricas analizadas previamente (tipo de contrato, método de pago, etc.) en vectores binarios (0 y 1) [2]. Asimismo, tal y como se determinó en el estudio de correlación previo (apartado 5.6.3), se procedió a la eliminación de la variable *TotalCharges* para evitar problemas de multicolinealidad con la variable de antigüedad (*tenure*).

5.7.2 Metodología de validación: K-Fold Cross-Validation

Con el objetivo de garantizar la robustez del modelo y evitar el sobreajuste (*overfitting*), se ha implementado una metodología de Validación Cruzada Estratificada (*Stratified K-Fold Cross-Validation*) con $k=5$ iteraciones (o *splits*) [13].

A diferencia de una simple división estática de entrenamiento y prueba (*Train-Test split*), esta técnica divide el conjunto de datos en 5 bloques proporcionales, manteniendo la tasa de abandono real en cada partición. El modelo se entrena 5 veces distintas, utilizando en cada iteración 4 bloques para el aprendizaje y reservando un bloque diferente para la validación. De este modo, se evalúa la capacidad de generalización del algoritmo sobre la totalidad del conjunto de datos de forma insesgada [2].

5.7.3 Estandarización y Escalado de Variables

Previo al entrenamiento del algoritmo, se implementó una fase de estandarización de las características predictoras mediante *StandardScaler*. Este proceso transforma las variables numéricas continuas para que presenten una media de 0 y una desviación típica de 1 [14].

Esta transformación es un requisito matemático ineludible para algoritmos basados en el cálculo de distancias espaciales, garantizando que variables con magnitudes dispares (como la cuota mensual en dólares frente a las variables dicotómicas de los servicios) no dominen o distorsionen el aprendizaje del modelo. Con el fin de asegurar una evaluación realista y evitar que el modelo tenga acceso anticipado a la información de validación (fenómeno conocido como filtración de datos o *data leakage*), los parámetros matemáticos de escalado (la media y la desviación típica) se calcularon de forma exclusiva utilizando únicamente la partición de entrenamiento [14]. A continuación, esa misma regla de transformación se aplicó a la partición de prueba, garantizando así la total independencia de los datos evaluados.

5.7.4 Entrenamiento del Modelo Base (SVM)

Para establecer una primera línea base (*Baseline*) de rendimiento, se ha seleccionado el algoritmo de **Máquinas de Vectores de Soporte (*Support Vector Classifier - SVC*)**. Se ha optado por esta técnica debido a su contrastada eficacia en problemas de clasificación binaria y su capacidad para trazar hiperplanos de separación robustos en espacios multidimensionales complejos, como el que conforman las variables sociodemográficas y de servicio de este estudio [7].

Siguiendo la directriz metodológica de esta fase exploratoria, el modelo se ha instanciado en su configuración por defecto, sin aplicar sintonización de hiperparámetros. Para evaluar su rendimiento global, se ha calculado la media de las cinco matrices de confusión generadas durante la validación cruzada. La **Figura 5.9.** expone el resultado promedio del modelo base:




Figura 5.9. Matriz de confusión media: SVM (parámetros por defecto).

Fuente: Elaboración propia

El análisis cuantitativo de esta matriz promedio revela el comportamiento inicial del modelo frente a la naturaleza desbalanceada del conjunto de datos:

- **Detección de la clase mayoritaria (Se Queda - 0):** El modelo exhibe una alta capacidad para identificar a los clientes fidelizados. De media,

clasifica correctamente a **936.2** clientes que permanecen en la compañía (Verdaderos Negativos), cometiendo un error muy bajo con solo **96.4** falsas alarmas (Falsos Positivos). Esto se traduce en una especificidad superior al 90%.

- **Detección de la clase minoritaria (Abandona - 1):** Por otro lado, la predicción de la fuga presenta un mayor desafío, un escenario previsible debido al desbalanceo intrínseco de la variable objetivo. El modelo logra identificar correctamente a **184.2** clientes que acaban abandonando (Verdaderos Positivos), pero clasifica erróneamente a **189.6** usuarios fugados como clientes estables (Falsos Negativos).

Por tanto, en términos globales, este primer acercamiento alcanza un nivel de precisión global (Accuracy) cercano al **80%**. No obstante, desde la perspectiva del negocio, su sensibilidad (Recall) para captar las fugas reales ronda el 50%. Esto indica que nos encontramos ante un modelo "conservador": es muy preciso cuando predice que un cliente es leal, pero deja escapar aproximadamente a la mitad de los usuarios que conforman la tasa de abandono real.

5.7.5 Evaluación Global de la Línea Base (Modelos por Defecto)

Con el propósito de disponer de un marco comparativo robusto frente al algoritmo SVM inicial, se ha ampliado la fase de modelado integrando el resto de los clasificadores seleccionados: Regresión Logística, k-Vecinos Más Cercanos (k-NN), Árbol de Decisión y Random Forest.

En esta primera iteración, todos los algoritmos se evaluaron con sus hiperparámetros por defecto, enfrentándose al desafío del desbalanceo natural del conjunto de datos (73.5% de clientes fieles frente a un 26.5% de abandonos). Los resultados obtenidos en las matrices de confusión medias tras la validación cruzada revelan las severas limitaciones de no tratar previamente este desbalanceo.

Por un lado, la Regresión Logística Base [3] mostró un comportamiento en el que detectó 204.4 fugas y cometió 169.4 Falsos Negativos, lo que supone un Recall aproximado del 54.6% (**ver Figura 5.10**). A pesar de mantener una alta tasa de

acierto en la clase mayoritaria (926 Verdaderos Negativos), este modelo resulta insuficiente para el objetivo de negocio propuesto, ya que deja sin detectar a casi la mitad de los clientes en riesgo de abandono.




Figura 5.10. Matriz de confusión media: Regresión Logística (parámetros por defecto).

Fuente: Elaboración propia

El algoritmo k-Vecinos Más Cercanos (k-NN) [6] mostró una capacidad predictiva muy limitada frente a la clase minoritaria (**ver Figura 5.11**), logrando una Sensibilidad de apenas el 51% (191.6 aciertos frente a 182.2 fugas no detectadas). Este bajo rendimiento se explica por su propia naturaleza espacial: al basar sus predicciones en votaciones por mayoría dentro de un entorno donde tres de cada cuatro clientes son fieles, la clase mayoritaria "absorbe" fácilmente el resultado de la votación. Además, intentar solucionar esto buscando un valor óptimo para k (el número de vecinos) resultaría ineficaz frente a un sesgo estructural tan marcado. Si ampliamos el vecindario (una k mayor), entrarán en la votación aún más clientes mayoritarios, agravando la invisibilidad de las fugas; por el contrario, si lo reducimos al mínimo (k=1 o k=3), el modelo sufrirá un sobreajuste severo al limitarse a memorizar casos aislados (ruido local), perdiendo su capacidad de generalizar frente a datos nuevos. A esto se añade que, al trabajar con tantas variables tras la dummificación, las distancias entre

clientes se distorsionan, dificultando que el algoritmo encuentre patrones claros. Sin embargo, en lugar de descartarlo por completo, se opta por reservar este modelo para una prueba posterior en el **apartado 5.7.14**. En dicha fase, se evaluará si el k-NN mejora sus resultados tras aplicar una técnica de selección de características (*Feature Selection*), entrenándolo exclusivamente con el núcleo de variables más determinantes que identifique posteriormente el modelo *Random Forest*. El objetivo será comprobar si una base de datos más limpia y sin ruido dimensional permite a este algoritmo ganar la precisión que le falta en esta fase inicial.




Figura 5.11. Matriz de confusión media: k-NN (parámetros por defecto).

Fuente: Elaboración propia

Finalmente, se evaluaron los clasificadores basados en la partición recursiva del espacio de características: el Árbol de Decisión (Decision Tree Classifier) [4] y el Bosque Aleatorio (Random Forest Classifier) [5]. El Árbol de Decisión ofrece una alta interpretabilidad de las reglas de negocio generadas, un factor diferencial para su posterior aplicación en campañas de marketing. Por su parte, el Random Forest, al ser un método de ensamblaje (*ensemble*) que combina múltiples árboles independientes, proporciona una mayor estabilidad y resistencia al sobreajuste (*overfitting*) [5].

Los resultados de estos modelos basados en árboles (**ver Figuras 5.12 y 5.13**) replicaron exactamente el mismo patrón general: mostraron una alta capacidad

para clasificar correctamente a los clientes fieles (alta especificidad), pero presentaron deficiencias notables a la hora de identificar las fugas (alta tasa de Falsos Negativos), confirmando que este sesgo es provocado directamente por el desbalanceo intrínseco de la variable objetivo y afecta a todas las familias de algoritmos.




Figura 5.12. Matriz de confusión media: Árbol de Decisión (parámetros por defecto).

Fuente: Elaboración propia




Figura 5.13. Matriz de confusión media: Random Forest (parámetros por defecto).

Fuente: Elaboración propia

5.7.6 Tratamiento del Desbalanceo de Clases: Estrategia de Pesos Penalizados

Tal y como ha revelado el análisis de la línea base, la asimetría en la distribución de la variable de abandono sesga el aprendizaje de los algoritmos hacia la clase mayoritaria. Para mitigar este efecto, y con el objetivo de optimizar la capacidad de clasificación, se ha implementado una estrategia de aprendizaje sensible al coste integrando el hiperparámetro `class_weight='balanced'` en aquellos algoritmos que lo soportan nativamente (excluyendo, por tanto, a k-NN).

Esta técnica matemática modifica internamente la función de coste de los algoritmos durante la fase de entrenamiento. De forma automática, el modelo asigna una mayor penalización a los errores cometidos al clasificar la clase minoritaria (Abandona), siendo este peso inversamente proporcional a su frecuencia en el conjunto de datos. En términos de negocio, esta configuración instruye a los algoritmos bajo la premisa de que fracasar en la detección de un cliente que se va a fugar (Falso Negativo) constituye un error estratégico mucho más grave que clasificar erróneamente a un cliente leal como propenso a la baja (Falso Positivo).

5.7.7 Resultados Comparativos de Clasificación tras el Balanceo

La aplicación del balanceo de clases generó un impacto dispar dependiendo de la naturaleza matemática de cada algoritmo. Al analizar las nuevas matrices de confusión medias, se evidenció un contraste significativo en el comportamiento de los modelos debido a su estructura matemática subyacente.

Por un lado, los algoritmos basados en fronteras matemáticas globales experimentaron una mejora radical. La Regresión Logística Balanceada (**ver Figura 5.14**) disparó su detección de fugas reales de 204.4 a 295.2, reduciendo los Falsos Negativos a tan solo 78.6, lo que supone alcanzar un Recall cercano al 79%. De manera idéntica, el modelo SVM experimentó un salto cualitativo espectacular (**ver Figura 5.15**), pasando de 184.2 a 292.0 Verdaderos Positivos, con solo 81.8 Falsos Negativos (Recall del 78.1%).




Figura 5.14. Matriz de confusión media: Regresión Logística con balanceo de pesos (*class_weight='balanced'*).

Fuente: Elaboración propia




Figura 5.15. Matriz de confusión media: SVM con balanceo de pesos (*class_weight='balanced'*).

Fuente: Elaboración propia

Sin embargo, este incremento en la sensibilidad exige asumir un claro compromiso técnico (*trade-off*): al penalizar tanto el error en la clase minoritaria, el clasificador se vuelve mucho más reactivo. Esto conlleva un aumento inevitable de las falsas alarmas (Falsos Positivos), que en el caso del SVM pasaron de 96.4 a 278.8, y en la Regresión Logística de 106.6 a 275, identificando como riesgos de fuga a usuarios que en realidad permanecen en la compañía.

Por otro lado, los modelos basados en particiones jerárquicas, como el Árbol de Decisión (**ver Figura 5.16**) y el Random Forest (**ver Figura 5.17**), mostraron una alarmante insensibilidad al balanceo de clases. El Árbol de Decisión apenas incrementó sus Verdaderos Positivos de 184.6 a 187.8, mientras que el Random Forest incluso empeoró ligeramente, bajando a 175.6.

Este fenómeno se explica por su tendencia al sobreajuste masivo: al crecer sin límite de profundidad por defecto, los árboles crean "hojas" puras que memorizan a los clientes fieles. Al ajustarse con tanto nivel de detalle a los datos de entrenamiento, la penalización global de pesos pierde su efectividad, volviendo inútil el ajuste. Esta divergencia demostró que el balanceo por sí solo no es suficiente para los modelos no paramétricos; requieren un control estricto de su arquitectura para evitar la memorización y forzar la generalización.




Figura 5.16. Matriz de confusión media: Árbol de Decisión con balanceo de pesos.

Fuente: Elaboración propia




Figura 5.17. Matriz de confusión media: Random Forest con balanceo de pesos.

Fuente: Elaboración propia

5.7.8 Diagnóstico de Sobreajuste en Modelos de Partición

La escasa mejoría que experimentaron los algoritmos basados en árboles tras incorporar el balanceo de clases (`class_weight='balanced'`) respaldaba la hipótesis inicial: la ineficacia de la penalización se debía a un grave problema de sobreajuste (*overfitting*) en la fase de entrenamiento. Este fenómeno es inherente a la naturaleza de los árboles de decisión cuando no se imponen restricciones a su crecimiento [4]. Para confirmar este diagnóstico, se procedió a evaluar el rendimiento de los modelos aislando las predicciones sobre el conjunto de entrenamiento (Train) frente a las del conjunto de validación (Test).

La comparación visual de las matrices de confusión revela de forma clara el comportamiento subyacente de los algoritmos bajo su configuración estructural base (manteniendo el balanceo de pesos activo). Tomando como ejemplo el **Árbol de Decisión Base** (Figura 5.18), los resultados en la fase de

entrenamiento rozan la perfección, cometiendo una media de apenas 0.4 errores de Falso Negativo y 15 Falsos Positivos sobre más de 5.600 registros. Sin embargo, al enfrentarse a datos no vistos previamente (Test), el modelo se desploma, disparando los Falsos Negativos hasta 186.0 casos medios. Este contraste masivo evidencia que el algoritmo carecía de capacidad de generalización, habiéndose limitado a memorizar el conjunto de entrenamiento.




Figura 5.18. Comparativa de matrices de confusión (Train vs Test) para el Árbol de Decisión Base. Evidencia de sobreajuste.

Fuente: Elaboración propia.

5.7.9 Tratamiento empírico mediante Regularización (Poda)

Para corregir esta memorización, se introdujo el hiperparámetro `min_samples_split`, un mecanismo de poda pre-entrenamiento descrito en la metodología CART [4], que exige que un nodo contenga un porcentaje mínimo de la muestra para generar una nueva regla de división.

La evaluación de distintos umbrales demostró una efectividad notable:

- **Con una restricción leve del 1% (Figura 5.19):** El modelo reduce parcialmente el sobreajuste, logrando bajar los Falsos Negativos en Test de 186.0 a 92.2.




Figura 5.19. Matriz de confusión en Test para el Árbol de Decisión con poda leve ($\text{min_samples_split} = 1\%$).

Fuente: Elaboración propia.

- **Con una restricción moderada del 5% (Figura 5.20):** Se observa una mejora sustancial en la capacidad de generalización. Al impedir que el árbol profundice excesivamente en ruido estadístico, el modelo comienza a asimilar de forma efectiva la directriz de priorizar la clase minoritaria ($\text{class_weight} = \text{'balanced'}$). Como resultado, los Falsos Negativos en Test experimentan una fuerte caída hasta los 79.6 casos.




Figura 5.20. Matriz de confusión en Test para el Árbol de Decisión con poda moderada

($\text{min_samples_split} = 5\%$).

Fuente: Elaboración propia.

- **Con una restricción severa del 10% (Figura 5.21):** El comportamiento no solo se estabiliza, sino que demuestra ser la configuración manual más robusta. Al exigir grupos más grandes para permitir una división, el modelo simplifica su estructura geométrica y logra una generalización ligeramente superior a la del 5%. Esto confirma que un árbol menos complejo es más eficaz para capturar los patrones reales de fuga sin memorizar ruido estadístico.




Figura 5.21. Matriz de confusión en Test para el Árbol de Decisión con poda severa

(*min_samples_split* = 10%).

Fuente: Elaboración propia.

5.7.10 Comportamiento paramétrico del SVM

De forma complementaria, se evaluó la estabilidad del modelo de Máquinas de Vectores de Soporte frente a modificaciones en su tolerancia al error (C) y su tipología de frontera matemática (Kernel), elementos fundamentales en su formulación teórica [7]. Aunque el algoritmo permite proyectar los datos mediante múltiples funciones, la investigación paramétrica se ha centrado en los kernels lineal y radial (RBF), al ser los más eficientes computacionalmente y los

recomendados por la literatura para el modelado predictivo sobre este volumen de datos tabulares [14].

- Partiendo de una **configuración estructural base** que mantiene activo el balanceo de pesos ($C=1.0$, $\text{kernel}='rbf'$, $\text{class_weight}='balanced'$) (**Figura 5.22**), el modelo demostró ser mucho más robusto que el árbol, con 81.8 Falsos Negativos y 278.8 Falsos Positivos en Test.




Figura 5.22 Matriz de confusión en Test para SVM con configuración estructural base.

Fuente: Elaboración propia.

- Al flexibilizar el margen con **$C=0.5$** (**Figura 5.23**), el modelo mejoró levemente su sensibilidad, reduciendo los Falsos Negativos a 78.4. Por el contrario, un nivel de exigencia estricto con **$C=2.0$** (**Figura 5.24**) empeoró este registro subiéndolo a 85.8, un síntoma clásico de leve sobreajuste.




Figura 5.23. Matriz de confusión en Test para SVM con margen flexible ($C=0.5$).

Fuente: Elaboración propia.




Figura 5.24. Matriz de confusión en Test para SVM con margen estricto ($C=2.0$).

Fuente: Elaboración propia.

- La prueba con el **Kernel Lineal (Figura 5.25)** arrojó el valor más extremo: logró la mejor tasa de detección de fugas (Falsos Negativos mínimos de 62.6), pero a costa de disparar las falsas alarmas (Falsos Positivos) hasta los 359.0 casos.




Figura 5.25. Matriz de confusión en Test para SVM con kernel lineal.

Fuente: Elaboración propia.

5.7.11 Optimización Automatizada (GridSearchCV)

Las pruebas empíricas anteriores demostraron la sensibilidad de los algoritmos ante modificaciones individuales. Sin embargo, en el modelado predictivo, los hiperparámetros no actúan de forma aislada, sino que interactúan entre sí [2]. Por ello, la fase final de sintonización se confió a un proceso de búsqueda exhaustiva en cuadrícula (*GridSearchCV*) asistido por validación cruzada (*StratifiedKFold* de 5 particiones).

El algoritmo evaluó más de 90 combinaciones paramétricas, estableciendo como función objetivo la maximización de la métrica **Recall** (Sensibilidad) [8], en alineación directa con la prioridad de negocio: detectar la mayor cantidad posible de clientes en riesgo de fuga.

Los resultados de la optimización revelaron las siguientes configuraciones óptimas:

1. Árbol de Decisión (Recall: 0.8855)

- **Parámetros óptimos:** *criterion='gini', max_depth=3, min_samples_split=0.01, class_weight='balanced'*.
- **Análisis:** Este resultado cobra todo su sentido al compararlo con la evaluación manual. Anteriormente, al permitir que el árbol creciera sin límite de altura, necesitábamos exigir grupos de clientes muy grandes (10%) para evitar que memorizara los datos. Sin embargo, el *GridSearchCV* ha optado por una estrategia más sencilla: limitar drásticamente la profundidad máxima a solo tres niveles de decisión (*max_depth=3*). Al ser un árbol tan corto, es matemáticamente incapaz de sobreajustar, lo que permite relajar la exigencia de la poda a tan solo un 1%. Además, el algoritmo ha seleccionado el Índice de Gini (*criterion='gini'*) como la métrica matemática más eficaz y rápida para evaluar la pureza de cada división en la metodología CART [4]. Esta combinación de simplicidad estructural y eficiencia matemática genera el modelo con mayor capacidad teórica para detectar fugas. Como se observa en su matriz de confusión (Figura 5.26), esta configuración

logra capturar la mayor cantidad de positivos reales del estudio, minimizando drásticamente los falsos negativos.




Figura 5.26. Matriz de confusión: Árbol de Decisión (parámetros óptimos tras GridSearchCV)

Fuente: Elaboración propia

2. Support Vector Machine (Recall: 0.8325)

- **Parámetros óptimos:** *kernel='linear', C=0.1, gamma='scale', class_weight='balanced'.*
- **Análisis:** El proceso de búsqueda confirmó la hipótesis teórica extraída de la evaluación manual: la proyección lineal del espacio vectorial maximiza la sensibilidad [7]. Además, el algoritmo optimizó la regularización reduciendo el parámetro de penalización a $C=0.1$, flexibilizando al máximo el margen de la frontera de decisión para capturar más verdaderos positivos. Como muestra la Figura 5.27, el modelo prefiere ser "generoso" al clasificar: acepta cometer algunos Falsos Positivos a cambio de asegurar que la gran mayoría de las fugas reales queden dentro del radar de la empresa.




Figura 5.27. Matriz de confusión: Support Vector Machine (parámetros óptimos tras GridSearchCV)

Fuente: Elaboración propia

3. Regresión Logística (Recall: 0.8138)

- **Parámetros óptimos:** `penalty='l1', C=0.01, solver='liblinear', class_weight='balanced'`
- **Análisis:** La optimización demuestra que la Regresión Logística alcanza su mejor rendimiento cuando se le aplica una restricción matemática muy estricta ($C=0.01$ combinada con la penalización L1 o *Lasso*). A nivel práctico y de negocio, esta configuración actúa como un "filtro inteligente": el algoritmo evalúa toda la información disponible del cliente y "apaga" automáticamente (reduciendo su peso a cero) aquellas variables que no ayudan a predecir el abandono [3]. Gracias a este filtrado interno, el modelo no se distrae con datos irrelevantes. En su lugar, concentra toda su capacidad predictiva en los pocos factores que verdaderamente impulsan la fuga, logrando así una alta tasa de detección (Recall) con un modelo muy limpio y fácil de interpretar. La eficacia de este

ajuste se aprecia en la Figura 5.28.




Figura 5.28. Matriz de confusión: Regresión Logística (parámetros óptimos tras GridSearchCV)

Fuente: Elaboración propia

4. Random Forest (Recall: 0.8079)

- **Parámetros óptimos:** $n_estimators=50$, $max_depth=5$, $min_samples_split=0.10$, $class_weight='balanced'$
- **Análisis:** El modelo de ensamblado, siguiendo la naturaleza estocástica descrita en su formulación original [5], optó por una arquitectura de baja complejidad (bosques de solo 50 árboles limitados a una profundidad máxima de 5 niveles y podas estrictas del 10%) para lograr su mejor récord, evitando que el agregado de decisiones generase ruido estadístico. La matriz de confusión resultante se muestra en la Figura 5.29.




Figura 5.29. Matriz de confusión: Random Forest (parámetros óptimos tras GridSearchCV)

Fuente: Elaboración propia

5.7.12 Interpretación de los Coeficientes del Modelo mediante Odds Ratios (OR)

Para que los resultados de la Regresión Logística Óptima tengan una utilidad real en la toma de decisiones de la empresa, es necesario traducir los coeficientes matemáticos a una métrica comercial llamada *Odds Ratio* (OR). En el mundo de los negocios, el OR sirve para medir el impacto directo y relativo que tiene cada característica del cliente sobre su probabilidad de irse de la compañía.

Un detalle fundamental de este análisis es que el proceso de optimización automatizada (GridSearchCV) aplicó un filtro inteligente sobre los datos. El algoritmo "apagó" por completo el efecto de muchas variables asignándoles un impacto neutral ($OR = 1.0000$). Esto significa que el modelo ha limpiado el ruido estadístico para ayudarnos a concentrar los esfuerzos y el presupuesto exclusivamente en los verdaderos detonantes del abandono.

La Tabla 5.30 muestra las variables que se mantuvieron "encendidas" y su impacto real en el negocio.

Variable del Cliente	Impacto (Odds Ratio)	Efecto Comercial
Internet por Fibra Óptica (<i>InternetService_Fiber optic</i>)	1.5039	🔥 Riesgo alto (Aumenta la fuga)
Pago por Cheque Electrónico (<i>PaymentMethod_Electronic check</i>)	1.1948	⚠️ Riesgo moderado (Aumenta la fuga)
Facturación Electrónica (<i>PaperlessBilling_Yes</i>)	1.1208	⚠️ Riesgo leve (Aumenta la fuga)
Soporte Técnico Experto (<i>TechSupport_Yes</i>)	0.9290	🛡️ Escudo protector (Frena la fuga)
Contrato de Un Año (<i>Contract_One year</i>)	0.8154	🛡️ Escudo protector (Frena la fuga)
Sin Servicio de Internet (<i>OnlineBackup_No internet service</i>)	0.7547	🛡️ Perfil ultra-estable (Frena la fuga)
Contrato de Dos Años (<i>Contract_Two year</i>)	0.6679	🛡️ Escudo fuerte (Frena la fuga)
Antigüedad en la compañía (<i>tenure</i>)	0.5149	🏆 El mejor freno (Frena la fuga)

Tabla 5.30. *Impacto real de las variables comerciales en el abandono de clientes*

Fuente: Elaboración propia.

Como se observa en la Tabla 5.30, las variables significativas se distribuyen en dos vertientes claramente diferenciadas:

- **Factores de Riesgo Críticos (OR > 1):** El servicio de internet por **Fibra Óptica** destaca como el mayor peligro para la fidelización de la empresa, con un OR de **1.5039**. Esto indica que, manteniendo el resto de variables constantes, los clientes con fibra óptica tienen un **50.39% más de probabilidades (u odds)** ($1.5039 - 1$) de causar baja que aquellos que disponen de otras conexiones, un patrón habitualmente ligado a incidencias técnicas iniciales o a una alta sensibilidad al precio tras finalizar promociones. Le siguen el pago manual por **cheque electrónico** ($OR = 1.1948$, un 19.48% más de riesgo) y la adhesión a la **factura sin papel** ($OR = 1.1208$, un 12.08% más de riesgo).
- **Factores Protectores Estructurales (OR < 1):** La **antigüedad (tenure)** del cliente se consolida como el freno más potente contra el abandono, presentando un OR de **0.5149**. En términos estadísticos, por cada mes adicional que un usuario permanece en la compañía, el riesgo relativo de darse de baja se reduce en un **48.51%** ($1 - 0.5149$). Por su parte, las políticas de retención contractuales demuestran que el disponer de un compromiso de **un año** reduce el riesgo de fuga en un **18.46%** ($1 - 0.8154$), mientras que un contrato a largo plazo de **dos años** duplica esta protección, disminuyendo la probabilidad de baja en un **33.21%** ($1 - 0.6679$). Asimismo, la contratación de servicios de valor añadido como el **soporte técnico experto** disminuye el riesgo de huida en un **7.10%** ($1 - 0.9290$). Por último, la variable **OnlineBackup_No internet service** registra un OR de **0.7547**, lo que representa una reducción del **24.53%** en el riesgo de abandono. Esta etiqueta identifica de forma indirecta a los usuarios que no tienen contratado el internet con la compañía y que, por tanto, tampoco requieren el servicio de copia de seguridad. Comercialmente, este grupo define al **perfil de cliente que solo tiene contratado el teléfono fijo de casa**: un segmento muy estable que

permanece ajeno tanto a las averías de la red de datos como a las ofertas de internet de la competencia.

5.7.13 Análisis del diagrama del Árbol de Decisión

Una vez obtenida la arquitectura óptima a través del proceso de *GridSearchCV*, se procede a la extracción de conocimiento mediante el análisis del diagrama estructural del árbol (ver Figura 5.30).




Figura 5.30. Diagrama del Árbol de Decisión Óptimo.

Fuente: Elaboración propia.

Como se observa en la estructura del árbol, el algoritmo determina que la variable más discriminante (nodo raíz) es la tenencia de un contrato bianual (Contract_Two year). A partir de esta primera división, el modelo segmenta a la base de clientes en dos grandes perfiles de comportamiento:

- **Perfil de Alta Retención (Contratos a largo plazo):** La rama derecha del árbol agrupa a los clientes que sí disponen de un contrato de dos años.

Dentro de este segmento, el modelo evalúa posteriormente los cargos mensuales (MonthlyCharges) y el método de pago (PaymentMethod_Electronic check). Se observa de manera empírica que los clientes con contratos largos, cargos mensuales moderados (es decir, que no pertenecen al grupo de las tarifas más caras) y que evitan el uso del cheque electrónico como método de pago constituyen el grupo con mayor lealtad, presentando la pureza más alta orientada a la retención (Clase 0: "Se Queda").

- **Perfil de Alto Riesgo (Contratos a corto plazo):** Por el contrario, la rama izquierda agrupa a los clientes sin contrato bianual. Al descender por esta rama, el modelo aísla primero a aquellos que tampoco tienen contrato anual (Contract_One year), agrupando así a los clientes con contratos de renovación mensual (*mes a mes*). El hallazgo analítico más significativo se produce en el último nivel de profundidad: al evaluar el tipo de conectividad, el modelo identifica que los clientes con contratos mensuales que además utilizan el servicio de Fibra Óptica (InternetService_Fiber optic) presentan la mayor probabilidad de abandono (Clase 1: "Abandona").

Como conclusión del modelo, la interpretación de los nodos terminales (hojas) revela que la duración del compromiso contractual es el principal indicador predictivo contra el abandono. Asimismo, el modelo destaca una anomalía crítica en el servicio de Fibra Óptica para los usuarios sin compromiso de permanencia. Este comportamiento sugiere una insatisfacción en este nicho específico, lo cual podría estar vinculado a la relación calidad-precio del servicio frente a las ofertas de la competencia.

A partir de estos resultados, se pueden definir tres líneas de actuación comercial concretas. En primer lugar, la empresa debe lanzar campañas exclusivas para los usuarios de fibra con facturación mensual, ofreciendo **descuentos o mejoras del servicio condicionados a la firma de un contrato de permanencia**. En segundo lugar, y para atajar el problema estructural de este nicho, resulta fundamental **auditar técnicamente la red de fibra y ajustar sus tarifas** para asegurar su competitividad en el mercado.

Por último, al confirmarse que el cheque electrónico incrementa el riesgo de baja, se debe **impulsar proactivamente la transición hacia métodos automatizados —como la domiciliación bancaria (*Bank transfer*) o el pago por tarjeta (*Credit card*)—**, eliminando así la fricción mensual asociada a este tipo de cobro. Con estas medidas, la compañía puede dejar atrás las políticas genéricas y enfocar su presupuesto de retención exactamente en los puntos críticos detectados por el modelo.

5.7.14 Identificación de Factores Críticos: Importancia de Variables (Random Forest)

Si el Árbol de Decisión analizado en el apartado anterior nos proporcionó un "mapa" lógico para entender el perfil exacto del cliente en riesgo, el modelo de *Random Forest* nos ofrece una visión global. Su objetivo es responder a una pregunta clave: de toda la información disponible, ¿qué variables son las más determinantes para predecir si un cliente abandonará la compañía? Para ello, se ha extraído la "Importancia de las Variables" (*Feature Importance*) del modelo óptimo de bosque aleatorio, limitando el gráfico a las 10 características principales para facilitar su análisis (**ver Figura 5.31**).

Para comprender este gráfico, es necesario entender qué miden los valores del eje horizontal (eje X), conocidos matemáticamente como la "reducción media de la impureza de Gini". En términos prácticos, este eje mide el "peso predictivo" o el porcentaje de utilidad que cada variable aporta al algoritmo. Dado que la suma de la importancia de todas las variables del conjunto de datos es igual a 1 (el 100%), si una característica alcanza un valor cercano a 0.200, significa que, por sí sola, es responsable de aproximadamente el 20% de la capacidad del modelo para distinguir entre clientes fieles y clientes fugados.

Al observar la distribución de las barras bajo esta premisa, destaca de forma categórica la existencia de un núcleo predictivo formado exclusivamente por tres variables. El factor más influyente es la **tenencia de un contrato bianual (*Contract_Two year*)**, acaparando la máxima cuota de importancia (rozando el 0.200). A este escudo primario de retención le siguen muy de cerca la **antigüedad histórica del cliente en la compañía (*tenure*)** y la **contratación**

del servicio de Internet por Fibra Óptica (InternetService_Fiber optic). Esto confirma empíricamente que la propensión al abandono está impulsada, por encima de todo, por el nivel de compromiso contractual del usuario y la madurez de su relación con la empresa.

De hecho, el aspecto más revelador del gráfico es el claro efecto de "codo" (una caída abrupta en la importancia relativa) que se produce inmediatamente después de este trío principal. Mientras que las tres primeras características dominan la toma de decisiones del algoritmo, la cuarta variable en el ranking — el uso de cheques electrónicos como método de pago (PaymentMethod_Electronic check)— sufre un descenso drástico, aportando un peso predictivo de poco más de 0.075. Esta pérdida de relevancia continúa de forma escalonada: la quinta variable, referente a la disposición de Soporte Técnico (TechSupport_Yes), apenas alcanza una importancia de 0.05, y la sexta desciende por debajo de ese umbral. Esta pronunciada asimetría demuestra que el resto de variables operativas del *Top 10*, aunque útiles, tienen un impacto meramente marginal en comparación con los tres factores principales.

Desde una perspectiva estratégica, esta jerarquización matemática proporciona a la dirección comercial una hoja de ruta sumamente focalizada. Las políticas de fidelización y los presupuestos de retención no deben dispersarse intentando mejorar todos los atributos del servicio a la vez. Por el contrario, la empresa logrará el mayor retorno de inversión si concentra sus recursos casi en exclusiva en **fomentar contratos a largo plazo, premiar la antigüedad del cliente y vigilar activamente la satisfacción en el crítico segmento de la fibra óptica.**




Figura 5.31. Gráfico de Importancia de Variables (Random Forest).

Fuente: Elaboración propia.

5.7.15 Optimización de k-NN mediante Selección de Características

Tal y como se anticipó en el apartado 5.7.5, el algoritmo k-NN demostró severas limitaciones en su fase inicial, fuertemente penalizado por el desbalanceo y la "maldición de la dimensionalidad". Con el objetivo de comprobar si este rendimiento deficiente era inherente a la naturaleza espacial del modelo o producto del ruido estadístico introducido por el exceso de variables, se ha evaluado nuevamente este algoritmo aplicando una técnica de Selección de Características (*Feature Selection*).

Tomando como referencia la jerarquía de importancia obtenida por el *Random Forest*, **se ha reducido el conjunto de datos** para que el k-NN entrene y prediga basándose exclusivamente en el núcleo de las tres variables más determinantes: la tenencia de contrato bianual (Contract_Two year), la antigüedad (tenure) y el uso del servicio de fibra óptica (InternetService_Fiber optic). De manera fundamental para el cálculo de métricas espaciales, las variables han sido

estandarizadas previamente (*StandardScaler*) para evitar que la escala numérica de la antigüedad tenga un peso desproporcionado frente a las variables binarias al calcular las distancias. Adicionalmente, para extraer el máximo potencial de este nuevo espacio tridimensional, se ejecutó un proceso de optimización de hiperparámetros (*GridSearchCV*) configurado para maximizar la métrica de Sensibilidad (*Recall*), asegurando la misma validación cruzada estratificada utilizada en modelos anteriores.

La búsqueda exhaustiva determinó que la configuración óptima para este espacio reducido requería evaluar a 15 vecinos (*n_neighbors=15*), utilizar la distancia euclidiana (*metric='euclidean'*) y ponderar los votos según la cercanía (*weights='distance'*). Sin embargo, los resultados obtenidos en la nueva matriz de confusión (ver Figura 5.32) revelan que esta depuración no ha logrado el efecto deseado sobre la clase minoritaria.

El modelo optimizado consigue clasificar correctamente a 953 clientes fieles (cometiendo solo 79 Falsos Positivos), pero fracasa de forma contundente en la detección de fugas: identifica apenas 153 abandonos y deja sin detectar 221 Falsos Negativos. Esto se traduce en una **Sensibilidad del 41%**, un rendimiento incluso inferior al obtenido con los parámetros por defecto.

A pesar de este intento de optimización metodológica, los resultados confirman de manera empírica que el k-NN no es adecuado para este problema de negocio. El hecho de que la métrica de Recall empeore indica que, al analizar estas tres variables, los clientes que abandonan y los que se quedan presentan características casi idénticas; es decir, sus perfiles están muy mezclados entre sí. Al existir tanto solapamiento, un algoritmo que funciona midiendo distancias físicas como el k-NN es incapaz de trazar una línea divisoria clara para separar a ambos grupos. Por el contrario, los modelos basados en árboles (como el Random Forest) no se basan en distancias, sino que aplican reglas lógicas y divisiones sucesivas, lo que les permite aislar mucho mejor a los clientes fugados aunque sean minoría. Con este experimento empírico se descarta definitivamente el uso de k-NN, justificando plenamente la necesidad de priorizar algoritmos capaces de compensar el desbalanceo y segmentar a los clientes mediante reglas condicionales.




Figura 5.32. Matriz de confusión media: k-NN (aplicado sobre base de datos reducida).

Fuente: Elaboración propia.

5.7.16 Análisis Global de Modelos: Curva ROC y AUC

La métrica AUC (*Area Under the Curve*) permite evaluar la capacidad discriminante global de los algoritmos de forma independiente al umbral de clasificación, midiendo su habilidad para ordenar correctamente a los clientes según su nivel de riesgo de fuga. En la Figura 5.33 se presentan las curvas ROC de los cuatro modelos superpuestas para facilitar su comparación visual.




Figura 5.33. Evaluación del rendimiento discriminante global mediante curvas ROC (Tasa de Verdaderos Positivos frente a Tasa de Falsos Positivos) y métrica AUC para los cuatro modelos finales

Fuente: Elaboración propia.

Los resultados confirman la solidez del modelado, ya que tres de los cuatro algoritmos superan el umbral de 0.80 en su AUC, situándose en un nivel de excelencia discriminante. La Regresión Logística (AUC = 0.8397) y el Random Forest (AUC = 0.8352) obtienen el mejor rendimiento, demostrando una alta capacidad para identificar los positivos reales manteniendo controlada la tasa de falsos positivos. Asimismo, el modelo Support Vector Machine muestra un comportamiento robusto con un AUC = 0.8183.

Por el contrario, el Árbol de Decisión registra el menor área de la comparativa (AUC = 0.7919). La morfología angulosa de su curva es consecuencia directa de las restricciones impuestas en su optimización: al limitar la profundidad máxima a tres niveles (max_depth=3) para evitar el sobreajuste, el algoritmo genera un número reducido de probabilidades únicas y, por tanto, menos puntos de corte evaluables en la gráfica.

En conclusión, este análisis certifica la fiabilidad predictiva de las arquitecturas desarrolladas. La Regresión Logística lidera ligeramente la ordenación teórica (AUC), mostrando una coherencia absoluta con la simulación financiera posterior

(Sección 5.8), donde este mismo algoritmo maximiza el beneficio neto del proyecto gracias a su equilibrio entre la detección de bajas y la minimización de los costes por falsos positivos.

5.8 Simulación de Impacto Económico y Optimización de Ofertas

Para determinar la viabilidad real del proyecto, no basta con medir la precisión estadística; es necesario traducir las predicciones a términos monetarios [15]. En este apartado se simula un escenario de negocio avanzado donde la empresa aplica una campaña de retención basada en la **optimización conjunta de dos variables: el porcentaje de descuento mensual y el umbral de riesgo para el lanzamiento de la oferta.**

5.8.1 Metodología de la Simulación

A diferencia de un modelo lineal simplificado, esta simulación asume dos premisas realistas de mercado fundamentadas en la econometría del marketing [18]:

1. **Elasticidad de la Retención:** Se asume que la probabilidad de que un cliente acepte la oferta y decida no abandonar la compañía aumenta con el porcentaje de descuento, siguiendo una función de saturación exponencial: $P(\text{éxito}) = 1 - e^{-6 \cdot \text{descuento}}$. El número 6 es un factor de sensibilidad diseñado para que, al ofrecer el descuento máximo del 50% (0.50), el exponente sea -3 . Como una función con base e elevada a -3 es casi cero (0.05), la probabilidad de éxito alcanza el 95%, indicando que pasar de ese umbral ya no aporta ninguna ventaja real al negocio. Este modelo probabilístico representa la respuesta del consumidor ante incentivos económicos [19].
2. **Reducción del margen de ingresos:** El beneficio neto se calcula como el ingreso recuperado de los clientes que realmente se iban a ir (Verdaderos Positivos), restando el "ingreso regalado" a aquellos clientes que el modelo marcó como fugas por error pero que en realidad eran fieles (Falsos Positivos) [11]. Para reducir este gasto innecesario, la simulación no se conforma con el corte automático de los modelos (que marcan como

"baja" a cualquiera que supere el 50% de riesgo). En su lugar, busca el punto de corte ideal probando con niveles de riesgo más exigentes (entre el 40% y el 85%). De este modo, la empresa puede volverse más "estricta" a la hora de conceder la oferta, asegurándose de dar el descuento solo a los clientes que de verdad están a punto de marcharse y protegiendo así sus ganancias.

La fórmula del impacto neto mensual aplicada mediante la librería Scikit-Learn [16] es:

$$\text{Impacto} = (\text{Cargos}_{TP} \cdot P_{\text{éxito}}) \cdot (1 - \text{desc}) - (\text{Cargos}_{FP} \cdot \text{desc})$$

5.8.2 Resultados y Punto de Inflexión

Tras ejecutar la simulación iterando de forma combinada los descuentos (del 5% al 100%) y los umbrales de decisión, se han obtenido los resultados presentados visualmente en la Figura 5.33 y resumidos numéricamente en la Tabla 5.34.




Figura 5.33. Curvas de Impacto Económico Neto según el porcentaje de descuento bajo umbrales óptimos.

Fuente: Elaboración propia.

<i>Modelo</i>	<i>Umbral Óptimo</i>	<i>Descuento Óptimo</i>	<i>Impacto Neto Máximo (Mensual)</i>
<i>Regresión Logística</i>	55%	19%	\$43,702.46
<i>Random Forest</i>	55%	20%	\$43,426.35
<i>SVM</i>	51%	18%	\$41,365.58
<i>Árbol de Decisión</i>	48%	17%	\$40,938.31

Tabla 5.34. Resultados de la optimización del impacto económico neto mensual por modelo.

Fuente: Elaboración propia.

Como se observa en la comparativa de la Tabla 5.34 y la Figura 5.33, todos los modelos presentan una morfología de "curva cóncava". Inicialmente, el beneficio aumenta a medida que el descuento es lo suficientemente atractivo para retener clientes. Sin embargo, al superar el umbral óptimo del **18%** (o 17% en el caso del árbol), el impacto económico comienza a descender de forma drástica. Esto ocurre porque el coste de aplicar descuentos a los Falsos Positivos y la reducción del margen en los clientes recuperados empieza a ser mayor que el beneficio de salvar nuevas fugas [15].

La gran ventaja de **añadir la optimización del umbral de riesgo** es que modelos como la Regresión Logística y el Random Forest logran desplazar sus curvas de beneficio hacia arriba al situar su punto de corte en el 55%. Esto les permite filtrar y descartar a los falsos positivos antes de activar la oferta, incrementando notablemente el beneficio económico máximo en comparación con una simulación tradicional que se limite a usar el umbral por defecto.

5.8.3 Conclusión del Análisis Económico

El análisis demuestra que la **Regresión Logística** y el **Random Forest** ofrecen el mayor rendimiento financiero, logrando rescatar más de **\$43,000 mensuales** de capital en riesgo.

Resulta de especial interés contrastar esto con la evaluación estadística previa, donde el **Árbol de Decisión** lideraba en *Recall* (minimizando los Falsos Negativos). A pesar de su alta capacidad para capturar a casi todos los clientes en riesgo de fuga, la simulación financiera demuestra que es el modelo menos rentable (\$40,938).

Esta inferioridad económica se explica por dos factores: su baja precisión (alto volumen de Falsos Positivos) y su incapacidad estructural para generar un ajuste fino del umbral. Al quedar su umbral óptimo estancado en el 48% (prácticamente el valor por defecto), el Árbol de Decisión satura la campaña con clientes fieles a los que se les otorga un descuento innecesario.

Por el contrario, el **Random Forest** y la **Regresión Logística** se consolidan como las soluciones óptimas para la organización. No solo demuestran una mayor precisión matemática, sino que su flexibilidad probabilística actúa como un "bisturí financiero", permitiendo establecer la línea de corte en un **55% de probabilidad de riesgo** para concentrar un descuento del **19%-20%** exclusivamente donde genera un retorno neto positivo [17].

6 CONCLUSIONES

6.1 Síntesis del Proceso y Métodos Empleados

El presente Trabajo de Fin de Grado ha abordado la problemática crítica de la pérdida de clientes (*Churn*) en el sector de las telecomunicaciones mediante la implantación de un flujo metodológico riguroso fundamentado en la Ciencia de Datos. A partir del conjunto de datos histórico de más de 7.000 clientes, el desarrollo experimental avanzó de forma secuencial a través de las siguientes fases analíticas:

- **Preprocesamiento y Limpieza de Datos:** Se garantizó la integridad del conjunto de datos mediante la resolución de valores nulos asociados a clientes con antigüedad cero y la eliminación de la variable de cargos totales (*TotalCharges*) para suprimir problemas de multicolinealidad estructural. Las variables categóricas se vectorizaron mediante la codificación *One-Hot Encoding* y las continuas se normalizaron para asegurar la equidad espacial en el cálculo de distancias.
- **Evaluación de la Línea Base, Balanceo e Interpretación:** La modelización inicial reflejó la vulnerabilidad de los algoritmos ante conjuntos de datos desbalanceados, registrando una sensibilidad de detección de bajas de apenas un 50%. Tras corregir este sesgo mediante la estrategia de pesos penalizados (*class_weight='balanced'*), se utilizaron los *Odds Ratios* (OR) de la Regresión Logística para transformar los coeficientes matemáticos en métricas comprensibles, identificando qué características del servicio actúan como frenos a la fuga y cuáles como detonantes de la baja.
- **Control del Sobreajuste y Optimización de Hiperparámetros:** Se diagnosticaron y subsanaron los efectos del sobreajuste (*overfitting*) en los modelos de partición (los Árboles y el Random Forest) mediante técnicas de regularización y podas estructurales. Para encontrar la combinación exacta y óptima de hiperparámetros, se ha hecho una *GridSearchCV* con validación cruzada estratificada de 5 particiones orientada a maximizar el *Recall*. El rendimiento final se evaluó mediante

curvas ROC y la métrica AUC, confirmando la capacidad de los algoritmos para clasificar correctamente a los usuarios según su nivel de riesgo.

- **Extracción de Conocimiento e Importancia de Variables:** Una vez sintonizados los modelos, se generó el diagrama visual del Árbol de Decisión final para examinar de forma clara las reglas lógicas que dividen a los clientes. En paralelo, se utilizó el criterio de impureza de Gini en el *Random Forest* para medir el peso real de cada variable en las predicciones. Este análisis demostró la existencia de tres factores dominantes sobre los demás: el tipo de contrato (especialmente el bianual), la antigüedad del cliente (*tenure*) y el uso de internet por fibra óptica.
- **Reducción Dimensional y Experimentación con k-NN:** Con el fin de simplificar el problema, se hizo una prueba aislando únicamente esas tres variables principales para entrenar el modelo de los k-Vecinos Más Cercanos (k-NN). Sin embargo, al analizar su matriz de confusión, se comprobó que el *Recall* empeoró. Al ser un algoritmo basado en distancias, el desbalanceo de los datos hace que los clientes que se quedan predominen en el espacio, provocando que el modelo sea incapaz de identificar correctamente a la minoría que se da de baja.
- **Simulación Económica:** Por último, se diseñó una simulación financiera avanzada que adaptaba los resultados a la realidad de la empresa. Mediante el uso de funciones de saturación y curvas de elasticidad exponencial, **el algoritmo no solo calculó el porcentaje de descuento idóneo, sino que iteró de forma dinámica los umbrales de riesgo entre el 40% y el 85% sobre la probabilidad continua de los modelos.** Esto permitió traducir los aciertos y fallos de los algoritmos en costes reales y beneficios netos, **encontrando el punto de corte exacto para activar la campaña y proteger el margen comercial.**

6.2 Evaluación del Cumplimiento de los Objetivos

Para constatar la validez de este proyecto, es necesario contrastar los resultados obtenidos con los objetivos específicos planteados en la introducción del documento:

1. Analizar el perfil del cliente propenso al abandono (Cumplido)

El análisis exploratorio de datos (EDA) cumplió este objetivo al revelar los patrones de comportamiento de los usuarios que abandonan la compañía. El perfil de alto riesgo quedó perfectamente acotado: clientes con contratos mes a mes, facturaciones mensuales elevadas, una antigüedad inferior a un año y que utilizan el cheque electrónico como método de pago habitual.

2. Identificar las variables clave en la retención (Cumplido)

Gracias al cálculo de la importancia de variables del *Random Forest* y a los *Odds Ratios* de la Regresión Logística, se consiguieron separar los factores secundarios de los realmente críticos. El objetivo se alcanzó al demostrar cuantitativamente que el tipo de contrato (el compromiso a uno o dos años actúa como un fuerte escudo de fidelización) junto con la antigüedad (*tenure*) y la contratación de fibra óptica constituyen el núcleo fundamental para predecir el comportamiento de la cartera.

3. Evaluar y comparar distintas técnicas de modelado predictivo (Cumplido)

Se construyó un marco comparativo que contrastó la **Regresión Logística**, los **Árboles de Decisión**, el **Random Forest**, los **k-Vecinos Más Cercanos (k-NN)** y las **Máquinas de Vectores de Soporte (SVM)**. Aunque mediante la optimización por GridSearchCV se logró corregir el sobreajuste específico que sufrían los modelos basados en árboles y las diferencias finales en la métrica AUC resultaron mínimas entre los principales algoritmos, el Árbol de Decisión demostró limitaciones prácticas debido a la rigidez de sus clasificaciones binarias, lo que incrementó los falsos positivos. En su lugar, el Random Forest y la Regresión Logística probaron ser las mejores opciones comerciales; al generar estimaciones de probabilidad continuas y bien distribuidas, permiten ordenar la cartera de clientes de mayor a menor riesgo de fuga, **lo que facultó al sistema para establecer un umbral de corte óptimo en el 55% de riesgo**, facilitando una asignación presupuestaria mucho más eficiente **al excluir a los falsos positivos antes de aplicar la oferta**.

4. Cuantificar el impacto económico de los modelos en el negocio (Cumplido)

Este objetivo se cumplió mediante el desarrollo de la simulación financiera, que permitió evaluar el impacto real de haber seleccionado el *Recall* como métrica de optimización. La simulación demostró que maximizar el *Recall* de forma estricta —como hace el Árbol de Decisión— resulta económicamente ineficiente para la empresa, ya que su rigidez estructural genera demasiados falsos positivos y dispara el gasto en clientes que no pensaban marcharse. En su lugar, la Regresión Logística y el Random Forest demostraron ser las opciones más rentables. El éxito económico de ambos modelos radica en su flexibilidad probabilística: al permitir desplazar el umbral de decisión hacia un exigente 55%, el sistema actúa como un "bisturí financiero" que filtra a los clientes fieles antes de aplicar el descuento, concentrando los recursos exclusivamente donde generan un retorno neto positivo

6.3 Conclusiones Finales y Líneas de Actuación Comercial

La conclusión general de este trabajo confirma que la aplicación de técnicas de Machine Learning permite sustituir las campañas de marketing masivas e ineficientes por estrategias de retención dirigidas que ordenan a los usuarios según su probabilidad real de abandono.

A partir de los hallazgos analíticos de la investigación, se proponen tres líneas de actuación comercial directa para la dirección de la compañía:

- **Revisión del servicio de fibra óptica y migración de contratos:** El modelo ha reflejado que el servicio de fibra óptica es un foco prioritario de fugas cuando el cliente no tiene un compromiso a largo plazo. Esto sugiere deficiencias en el precio o problemas técnicos frente a la competencia. Se recomienda auditar la calidad del servicio técnico de fibra y lanzar una campaña proactiva de fidelización dirigida a este segmento para migrarlos hacia contratos anuales mediante descuentos estratégicos.
- **Incentivación de métodos de pago automáticos:** Dado que el uso del cheque electrónico está fuertemente asociado con el abandono debido a

la fricción psicológica que supone obligar al cliente a autorizar el pago de forma activa y manual cada mes, la empresa debe impulsar una transición proactiva hacia la domiciliación bancaria o el cargo automático en tarjeta. Automatizar el proceso elimina la necesidad de una interacción consciente recurrente con la factura, lo que reduce drásticamente las bajas voluntarias por revisión de costes.

- **Optimización del presupuesto de retención:** La simulación económica demostró que conceder descuentos indiscriminados reduce drásticamente el margen de beneficio. El negocio obtendrá su máximo retorno financiero si concentra sus recursos en las alertas generadas por los modelos probabilísticos (Regresión Logística o Random Forest). La dirección comercial debe establecer la línea de corte de la campaña exclusivamente en aquellos clientes que superen un 55% de probabilidad de abandono, aplicando a dicha población seleccionada un incentivo comercial del 19% (si se implementa la Regresión Logística) o del 20% (si se opta por el Random Forest). Esta combinación exacta es la que maximiza la retención real minimizando la destrucción del margen comercial.

7 BIBLIOGRAFÍA

- [1] Kotler, P., & Keller, K. L. (2016). *Dirección de Marketing* (15ª ed.). Pearson Educación.
- [2] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: with Applications in R*. Springer.
- [3] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). John Wiley & Sons.
- [4] Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth International Group.
- [5] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. *(Esta es la referencia canónica. Leo Breiman es el creador del Random Forest)*.
- [6] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21-27. *(Es el paper clásico que fundamentó matemáticamente el k-NN)*.
- [7] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297.
- [8] Powers, D. M. (2011). Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37-63.
- [9] Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861-874.
- [10] Reichheld, F. F. (2001). *The Loyalty Effect: The Hidden Force Behind Growth, Profits, and Lasting Value*. Harvard Business School Press.
- [11] Gallo, A. (2014). The Value of Keeping the Right Customers. *Harvard Business Review*. Recuperado de hbr.org.
- [12] Accenture. (2013). *Global Consumer Pulse Research: The Switching Economy*. Accenture Strategy Report.
- [13] Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 2, 1137-1143.
- [14] Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling*. Springer.

- [15] Blattberg, R. C., Kim, B. D., & Neslin, S. A. (2008). *Database Marketing: Analyzing and Managing Customers*. Springer Science & Business Media.
- [16] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [17] Verbeke, W., Martens, D., Mues, C., & Baesens, B. (2011). Building comprehensible customer churn prediction models with advanced rule induction techniques. *Expert Systems with Applications*, 38(3), 2354-2364.
- [18] Hanssens, D. M., Parsons, L. J., & Schultz, R. L. (2003). *Market Response Models: Econometric and Time Series Analysis*. Kluwer Academic Publishers.
- [19] Fader, P. S., & Hardie, B. G. (2009). Probability models for customer departure. *In Handbook of Database Marketing* (pp. 419-436). Springer.